



# Modélisation et prévision du prix de l'Or : *modèles de séries temporelles et d'apprentissage statistique*

Antonin Meudic  
Thomas Goumont  
Tom O'Connor  
Adrien Gibert



# Objectifs du projet et défis

**Objectif** : Modéliser le prix de l'or à travers une analyse rigoureuse de séries temporelles

**Défis** : un actif complexe à modéliser

- **Une Valeur Refuge** : tensions géopolitiques
- **Un Actif Spéculatif** : animal spirits

→ Nécessite une compréhension approfondie des données avant toute modélisation



# Données et diagnostique statistique

20 ans de données

- De prime abord :
  - > les **rendements stationnaires**
  - > les **prix non-stationnaires**



Augmented Dickey–Fuller sur les  
rendements:  
→ p-value: 0.01



- Nous travaillons avec les **log-  
rendements**



$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) \rightarrow \sum_{t=1}^T r_t = \ln\left(\frac{P_T}{P_0}\right)$$



Figure 1 – Prix proxy journalier de l'or  $P_t = 10 \times$  Clôture GLD (Yahoo Finance), 2005–2025

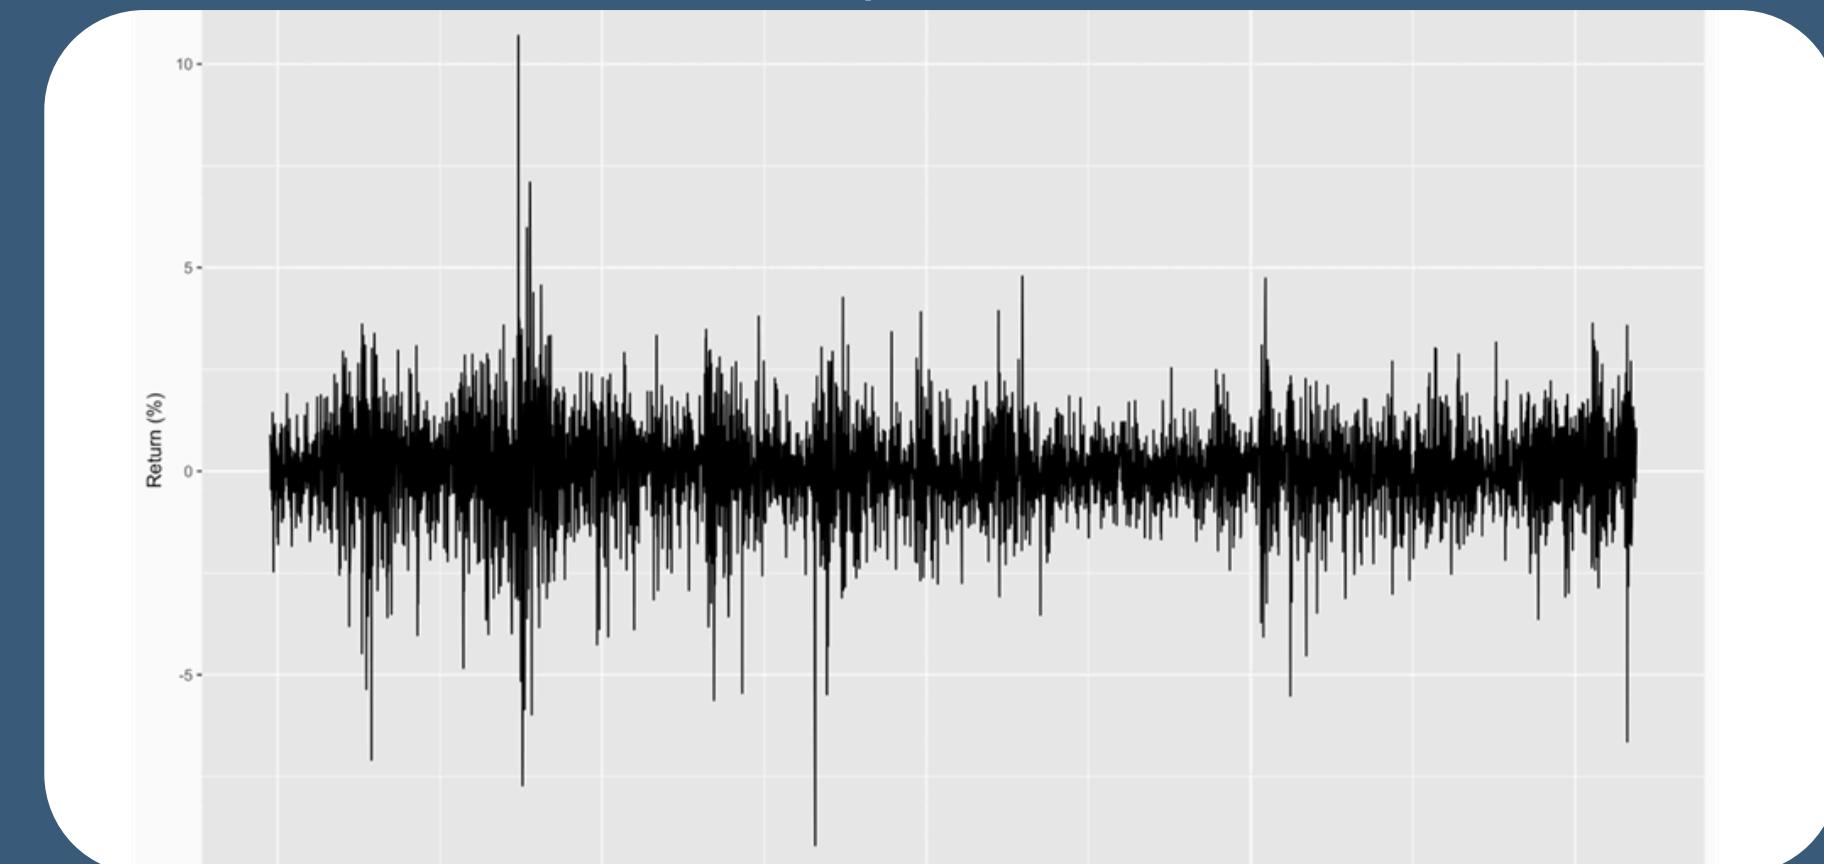
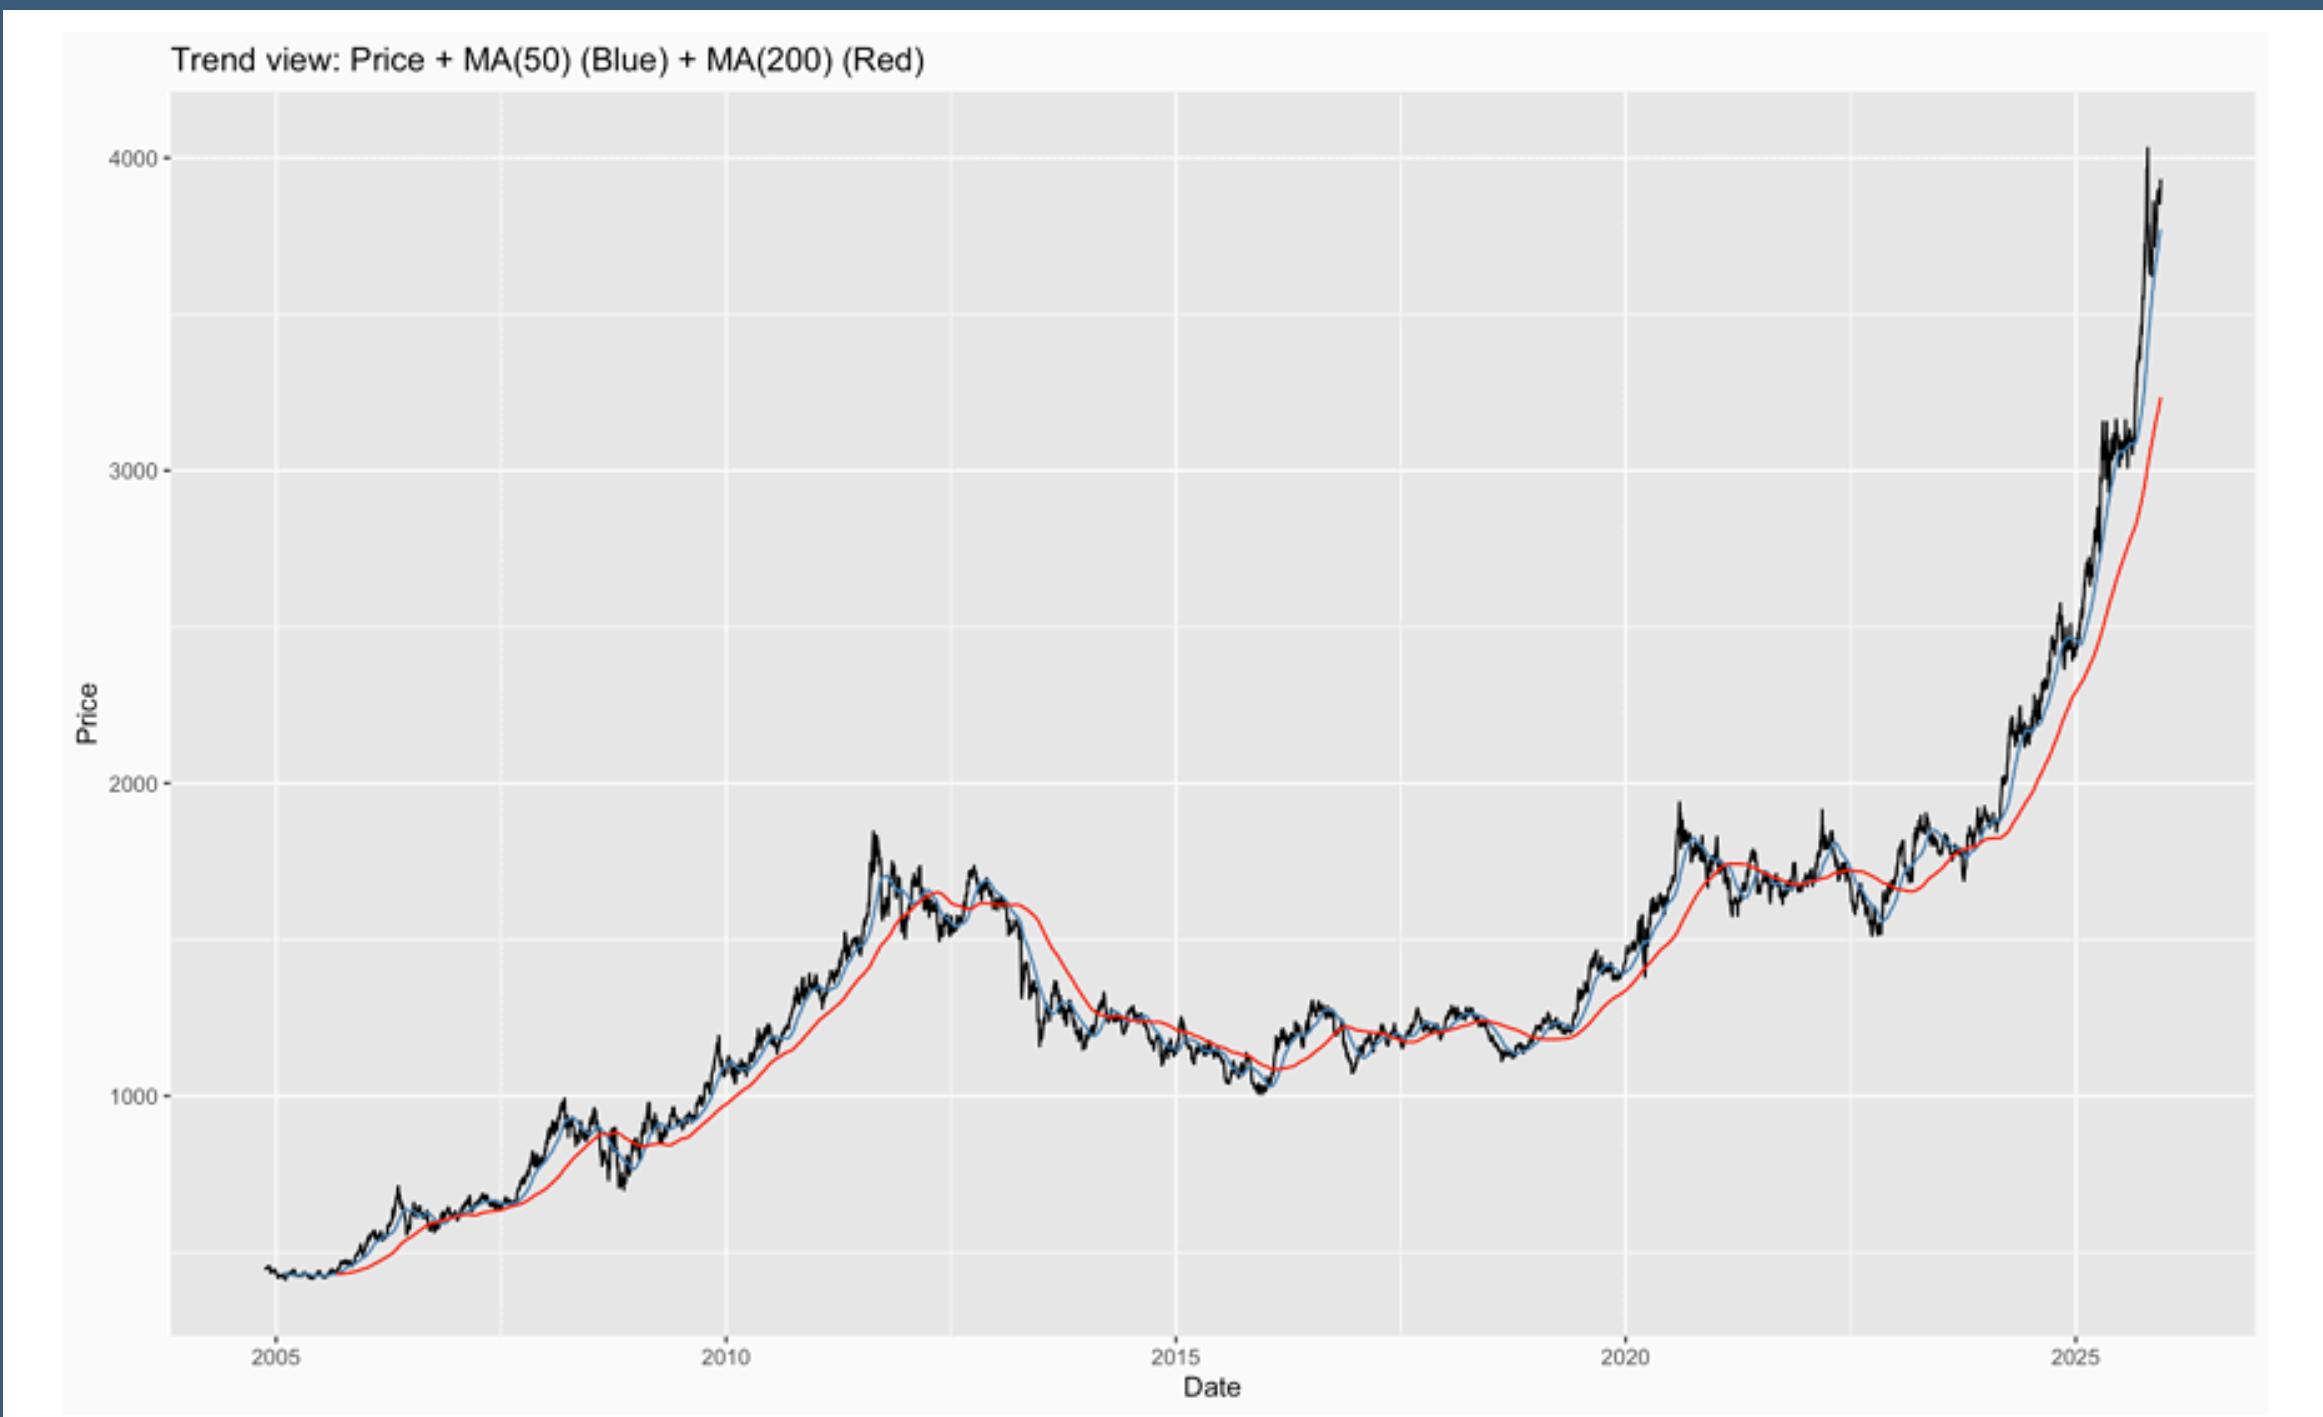


Figure 2 – Log-rendements journaliers  $r_t$  (en %)

# Nature cyclique de l'or

Présence de régimes distincts dans la dynamique du prix de l'or due à :



- **Taux d'intérêt réels** → coût d'opportunité  
(ne génère pas de rendement)
- **Cours du dollar** → effet de change
- **Inflation et anticipations** → couverture contre l'inflation
- **Volatilité** → valeur refuge
- **Politique monétaire** (banques centrales)
- **Chocs géopolitiques** → hausse de la demande refuge
- **Demande institutionnelle** (banques centrales, ETF)

# 2004–2011 : Régime de marché haussier



- La baisse des taux d'intérêt réels après la bulle dot.com
- Conditions monétaires mondiales accommodantes (QE)

# 2012–2015 : Régime de marché baissier



- **Hausse des taux d'intérêt réels**
- **Appréciation du dollar**
- **Animal spirits négatifs : désengagement des investisseurs**

# 2016-2019 : Régime de stabilisation



- Taux réels faibles
- Incertitudes politiques récurrentes (Brexit, Trade Wars)
- Dollar fort mais instable

# 2020-2025 : Régime de marché haussier



- Politiques monétaires accommodantes
- Forte incertitude géopolitique
- Demande de valeur refuge élevée

# Les Facteurs Exogènes

Les relations entre l'or, le dollar et les taux réels **sont stables à long terme**, mais peuvent **s'inverser temporairement** lors de chocs macroéconomiques, de crises financières

$$P_t^{\text{Gold}} = f(-r_t^{\text{real}}, -\text{USD}_t, +\mathcal{L}_t, +\mathcal{R}_t, +\pi_t^e) \rightarrow$$

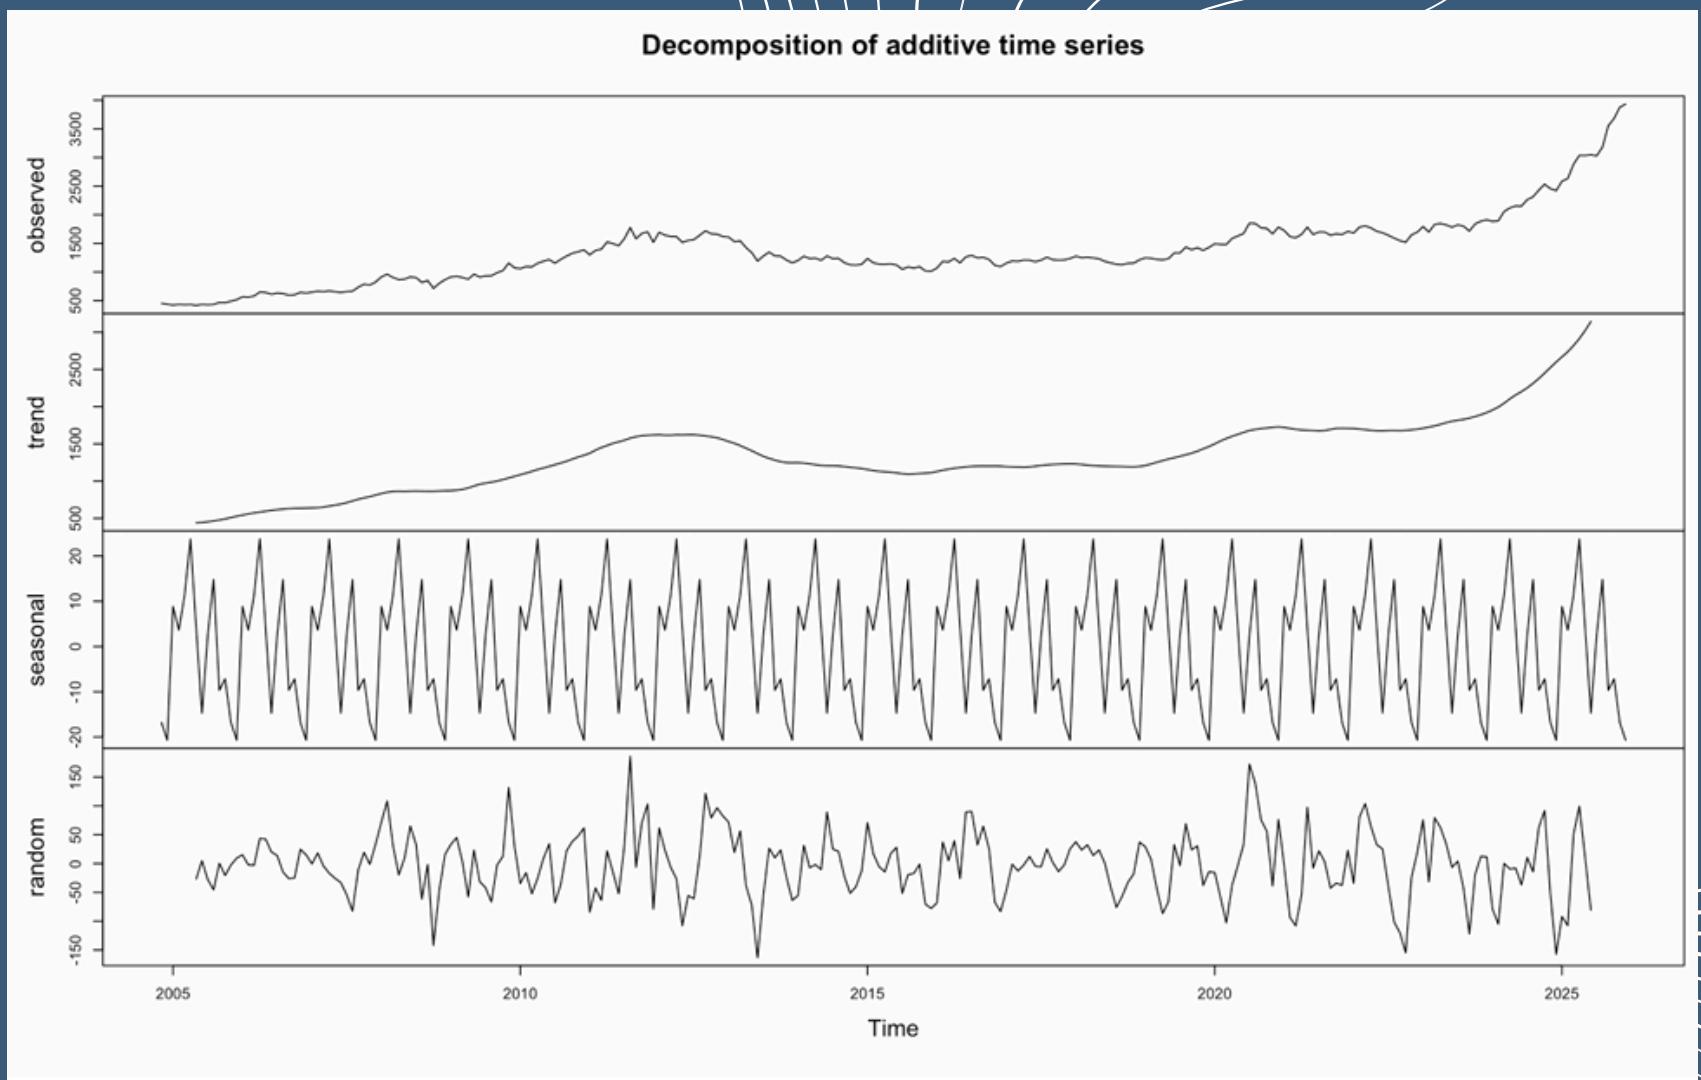
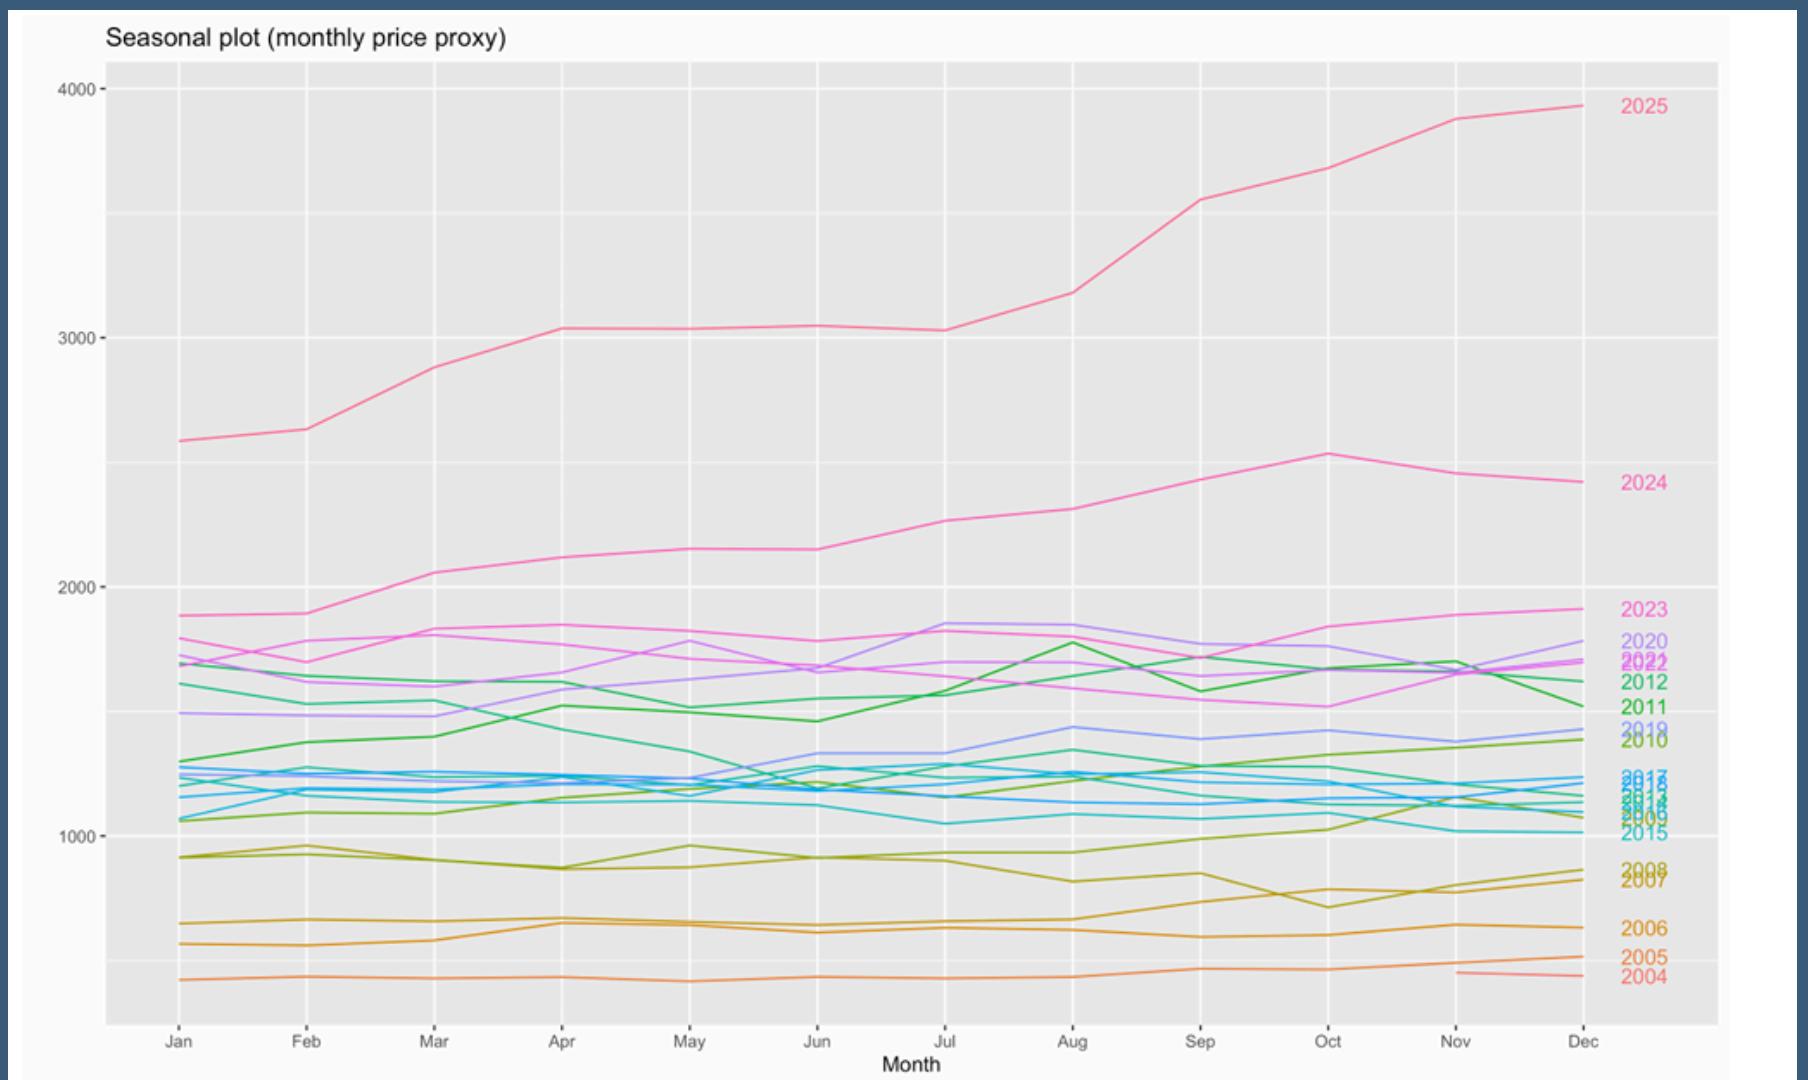
- $r_t^{\text{real}}$  : taux d'intérêt réels
- $\text{USD}_t$  : cours du dollar
- $\mathcal{L}_t$  : liquidité globale
- $\mathcal{R}_t$  : risque financier et géopolitique
- $\pi_t^e$  : inflation anticipée

# Saisonnalité ?

Mensuelle, trimestrielle ?



Absence de saisonnalité  
claire



Un test ANOVA appliqué aux rendements mensuels ne met pas en évidence de saisonnalité calendaire significative  
(p-value = 0,59)

# Outliers

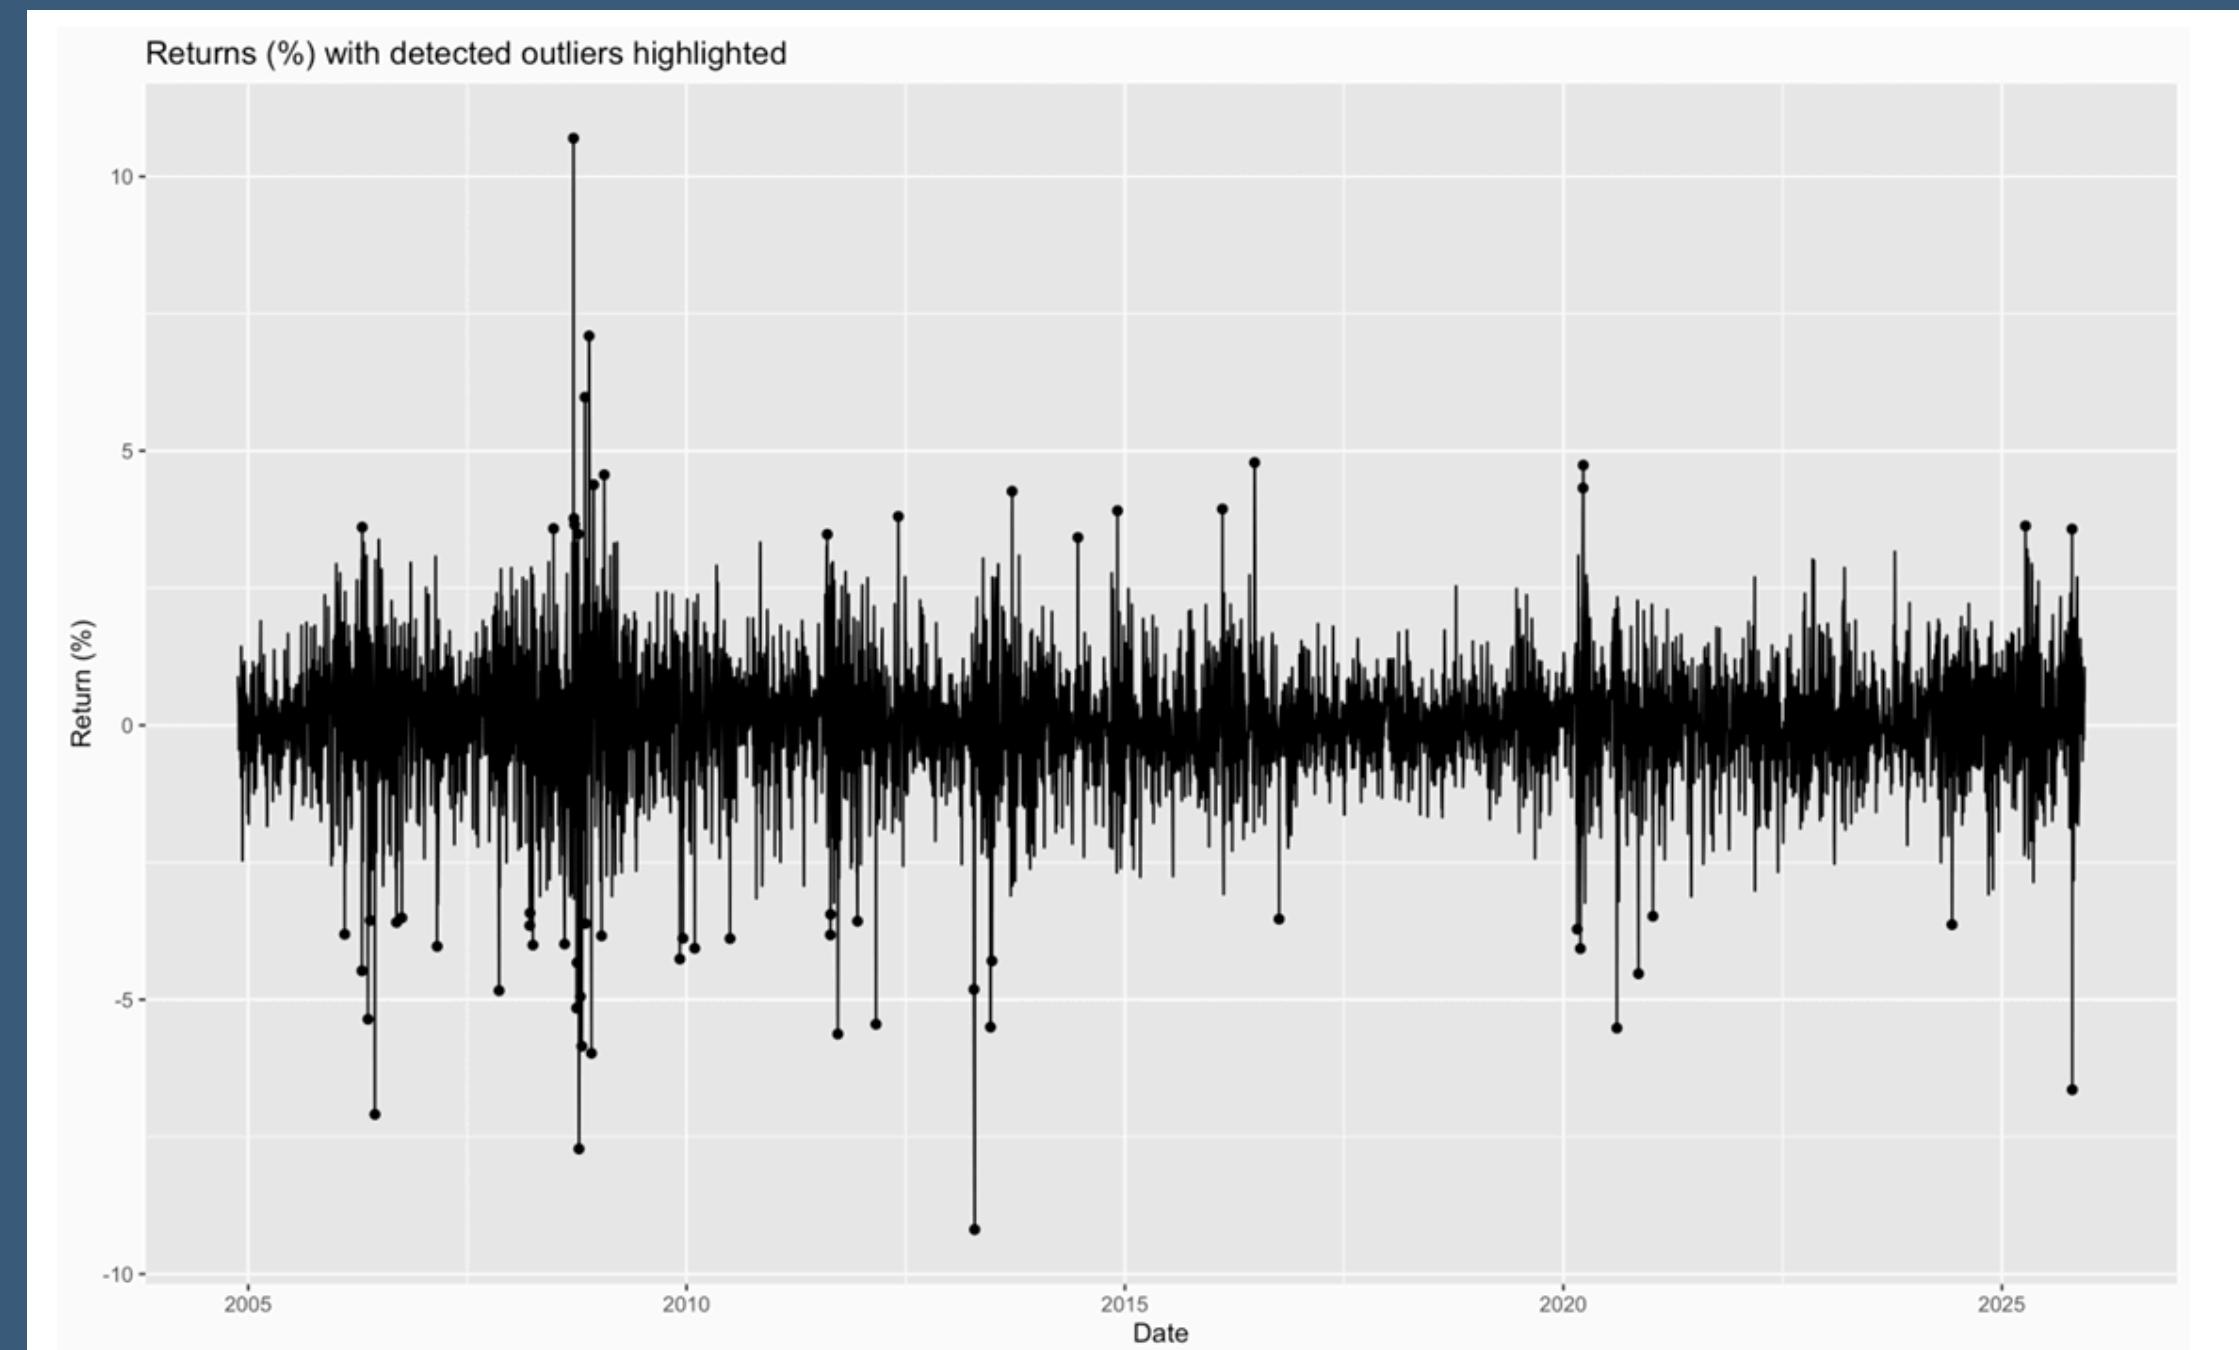
Chocs rares mais **extrêmes** concentrés lors des périodes de crise et une volatilité dépendante du régime **concentrés lors des périodes de crise**

$$z_t = \frac{r_t - \text{median}(r)}{1.4826 \cdot \text{MAD}(r)}$$

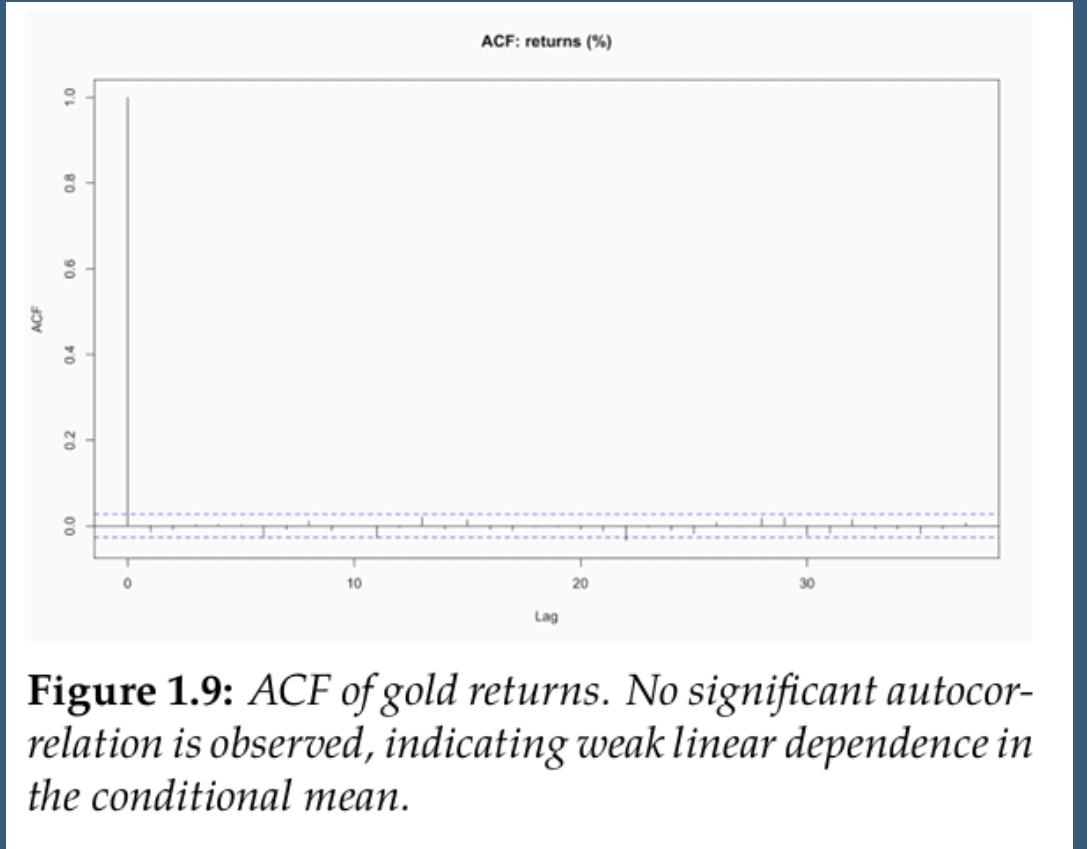
Dates clés :

- 2008-09-17 +10.69%
- 2013-04-15 -9.191%
- 2008-10-10 -7.721%

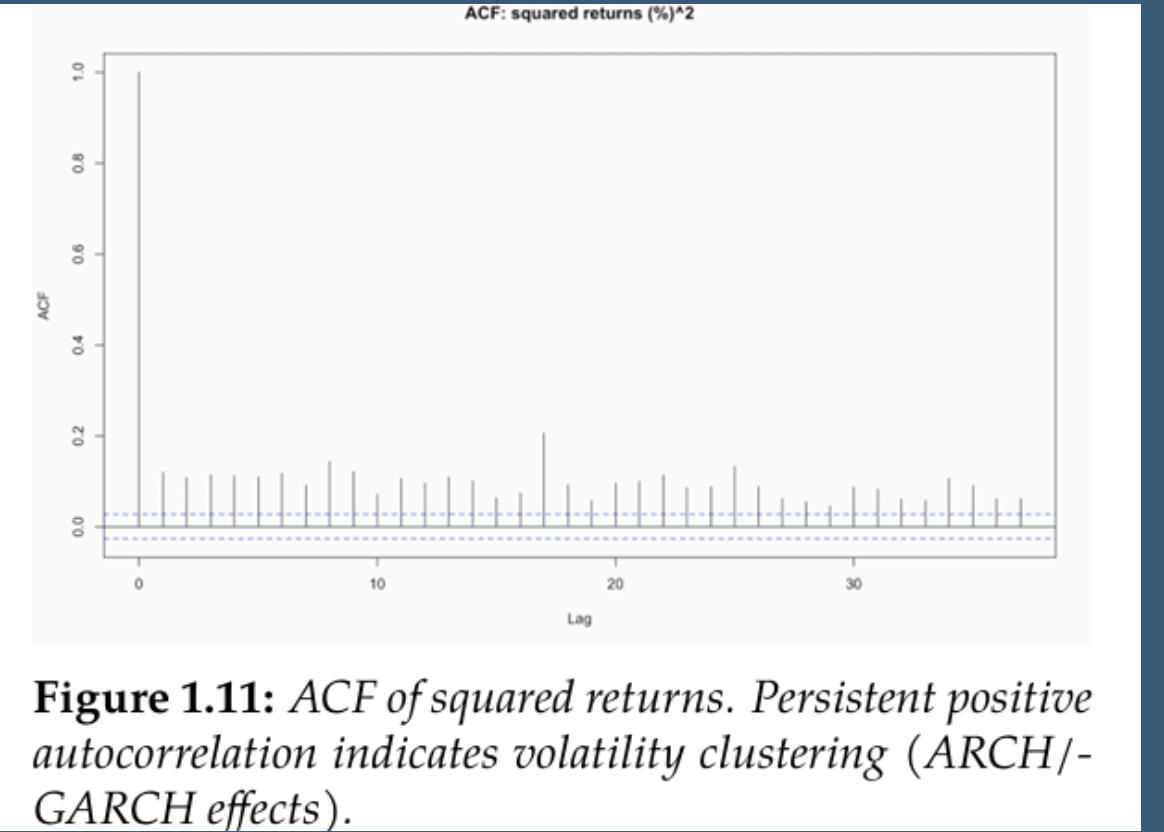
→ Phénomène de clustering :  
Modèle GARCH?



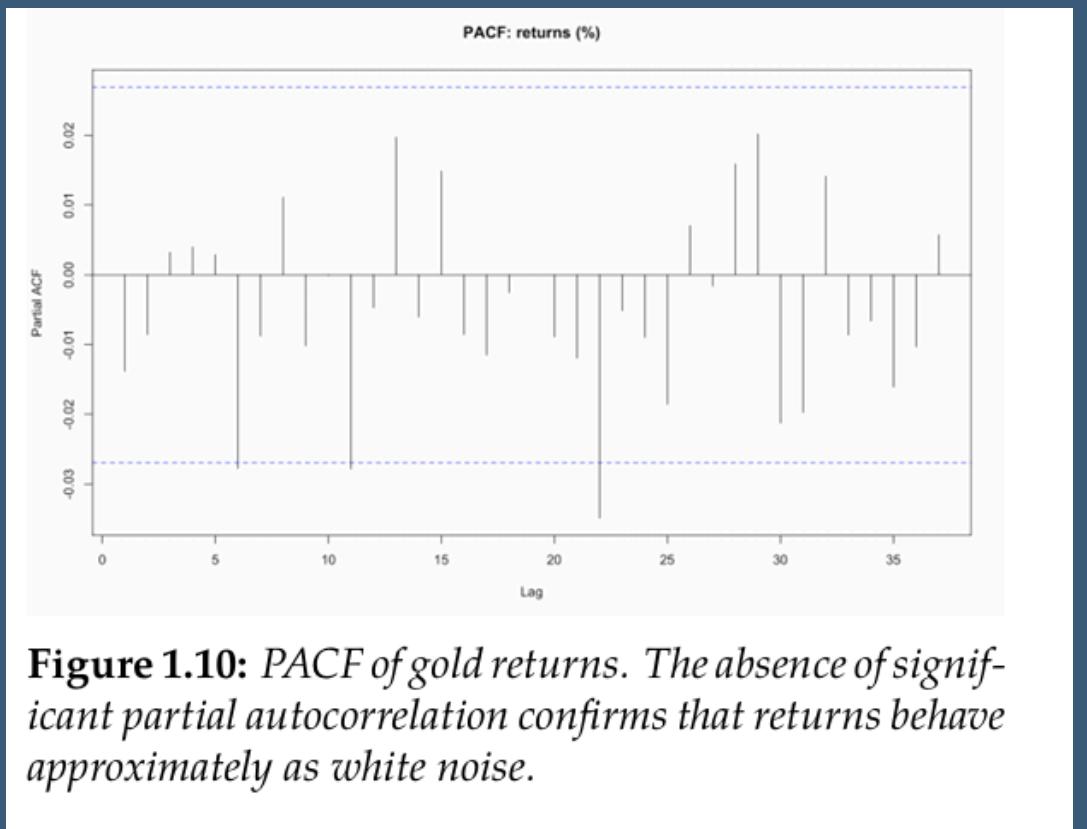
# Modèle ARMA ?



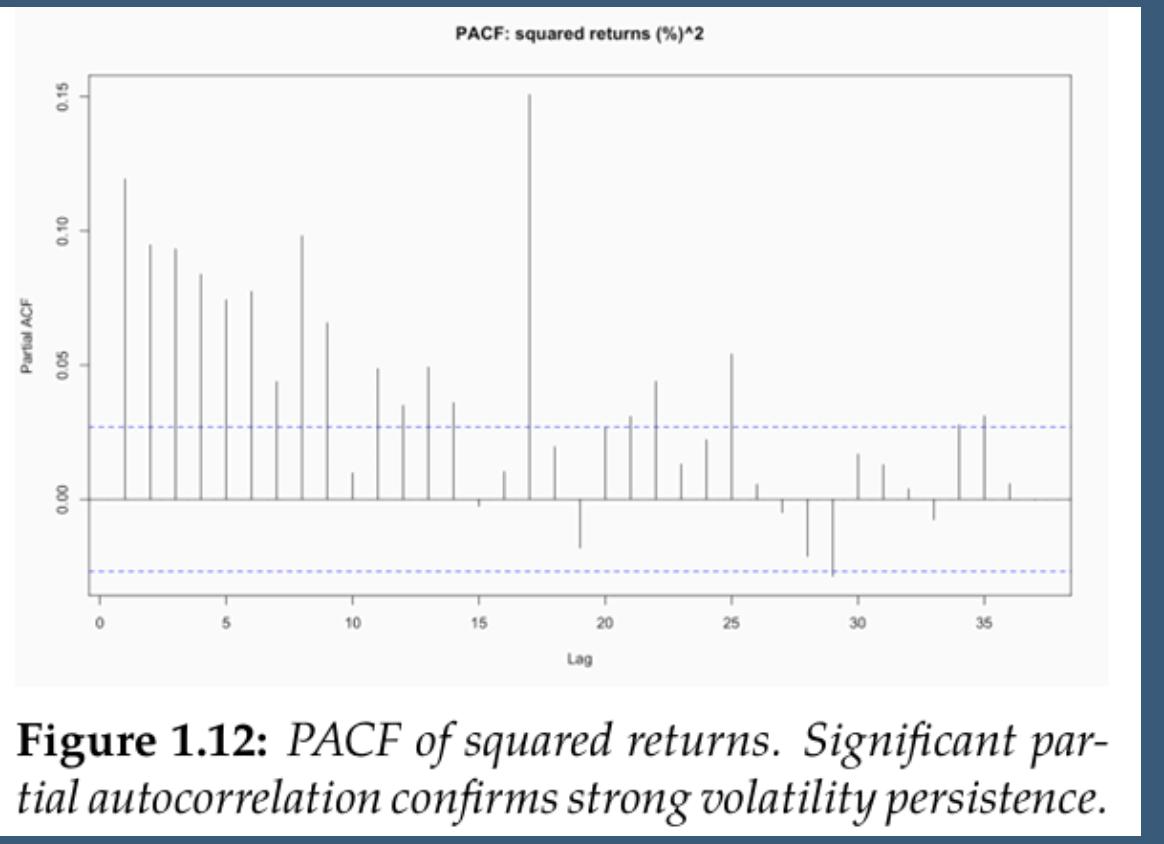
**Figure 1.9:** ACF of gold returns. No significant autocorrelation is observed, indicating weak linear dependence in the conditional mean.



**Figure 1.11:** ACF of squared returns. Persistent positive autocorrelation indicates volatility clustering (ARCH-/GARCH effects).



**Figure 1.10:** PACF of gold returns. The absence of significant partial autocorrelation confirms that returns behave approximately as white noise.



**Figure 1.12:** PACF of squared returns. Significant partial autocorrelation confirms strong volatility persistence.

## Test de Ljung-Box:

- $r_t$ : le test ne permet pas de rejeter l'hypothèse nulle d'absence d'autocorrélation ( $p = 0,68$ ).
- $r_t^2$ : le test rejette fortement l'hypothèse nulle ( $p < 2,2 \times 10^{-16}$ )  
→ Modèle GARCH est adapté

Sélection ARMA par recherche sur grille (p, q) sur les rendements stationnaires (critère AIC)  
→ ARMA(0,0) retenu : absence d'autocorrélation exploitable

$$r_t = \mu + \varepsilon_t$$

$$\mu = 0.1128\%$$

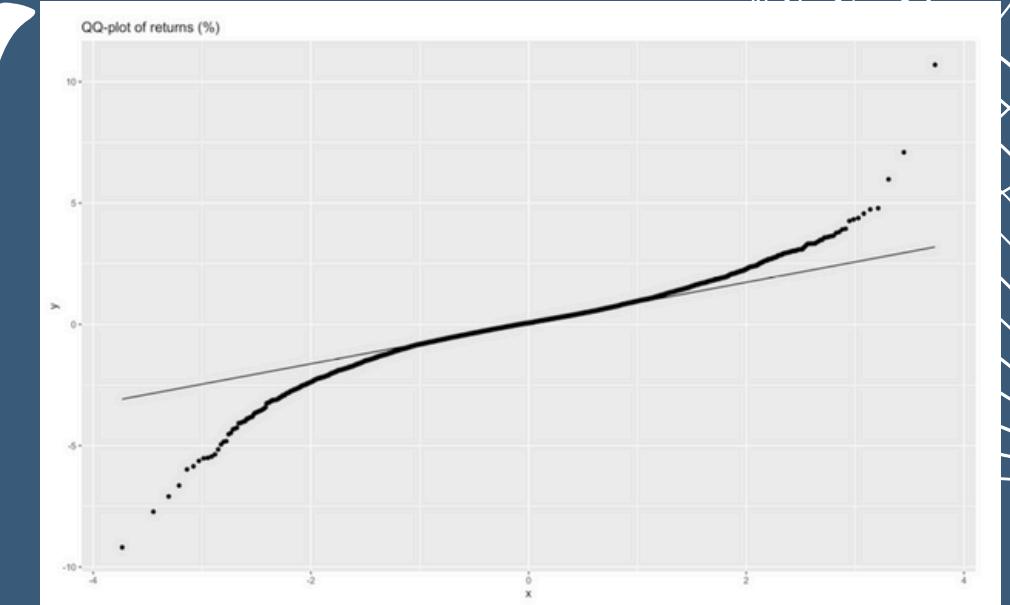
# Modèle ARIMA-X, FARIMA?

**Table 1.3: Comparison of GARCH-family volatility models**

Model	AIC	BIC	QLIKE <sub>OOS</sub>	MSE <sub>OOS</sub>	LB <sub>10</sub> (res)	LB <sub>10</sub> (res <sup>2</sup> )	ARCH-LM <sub>12</sub>
GARCH(1,1)-t	5342.03	5369.22	<b>1.2018</b>	<b>9.607</b>	0.518	0.703	0.821
GJR-GARCH(1,1)-t	5331.14	5363.77	1.2206	9.806	0.641	0.568	0.695
EGARCH(1,1)-t	5335.87	5368.50	1.2184	9.904	0.625	0.479	0.610
FIGARCH(1,1)-t	5343.39	5376.02	1.2680	10.200	0.487	0.850	0.932

$$r_t = 0.0003 - 0.0053 \Delta r_t^{\text{real}} + 0.0266 \Delta \text{DXY}_t - 0.0013 \Delta \pi_t^e - 0.0003 \Delta \text{VIX}_t + \varepsilon_t$$

	coef	std err	z	P> z	[0.025	0.975]
const	<b>0.0003</b>	<b>0.000</b>	<b>2.221</b>	<b>0.026</b>	<b>3.97e-05</b>	<b>0.001</b>
d_real	-0.0053	0.005	-1.164	0.244	-0.014	0.004
d_dxy	0.0266	0.041	0.653	0.514	-0.053	0.107
d_breakeven	-0.0013	0.008	-0.170	0.865	-0.017	0.014
d_vix	-0.0003	0.000	-2.819	0.005	-0.001	-0.000



- **Queues épaisse**  
marquées (kurtosis  $\approx 8,9$ )
- **Normalité rejetée**  
(Kolmogorov–Smirnov)

→ **L'absence de dépendance linéaire journalière significative**  
conduit à privilégier des  
**modèles non linéaires** ou à  
**mémoire**

# Modèle LSTM

Le problème avec ARMA-GARCH-t : il ne permet pas modéliser l'or car il prédit toujours la moyenne

Modèle ARMA

$$r_t = \mu + \varepsilon_t \rightarrow \hat{r}_{t+1} = \mu$$

La Solution : Modèle LSTM

$$\left\{ \begin{array}{l} f_{\text{LSTM}}(\mathbf{X}_t) \quad \mathbf{X}_t = [\mathbf{x}_{t-249}, \mathbf{x}_{t-248}, \dots, \mathbf{x}_t] \\ \mathbf{x}_t = (r_t, \Delta \text{Real10y}_t, \Delta \text{BE10y}_t, \Delta \text{VIX}_t, \Delta \log(\text{DXY}_t)) \end{array} \right.$$

Des prédictions plus robustes :

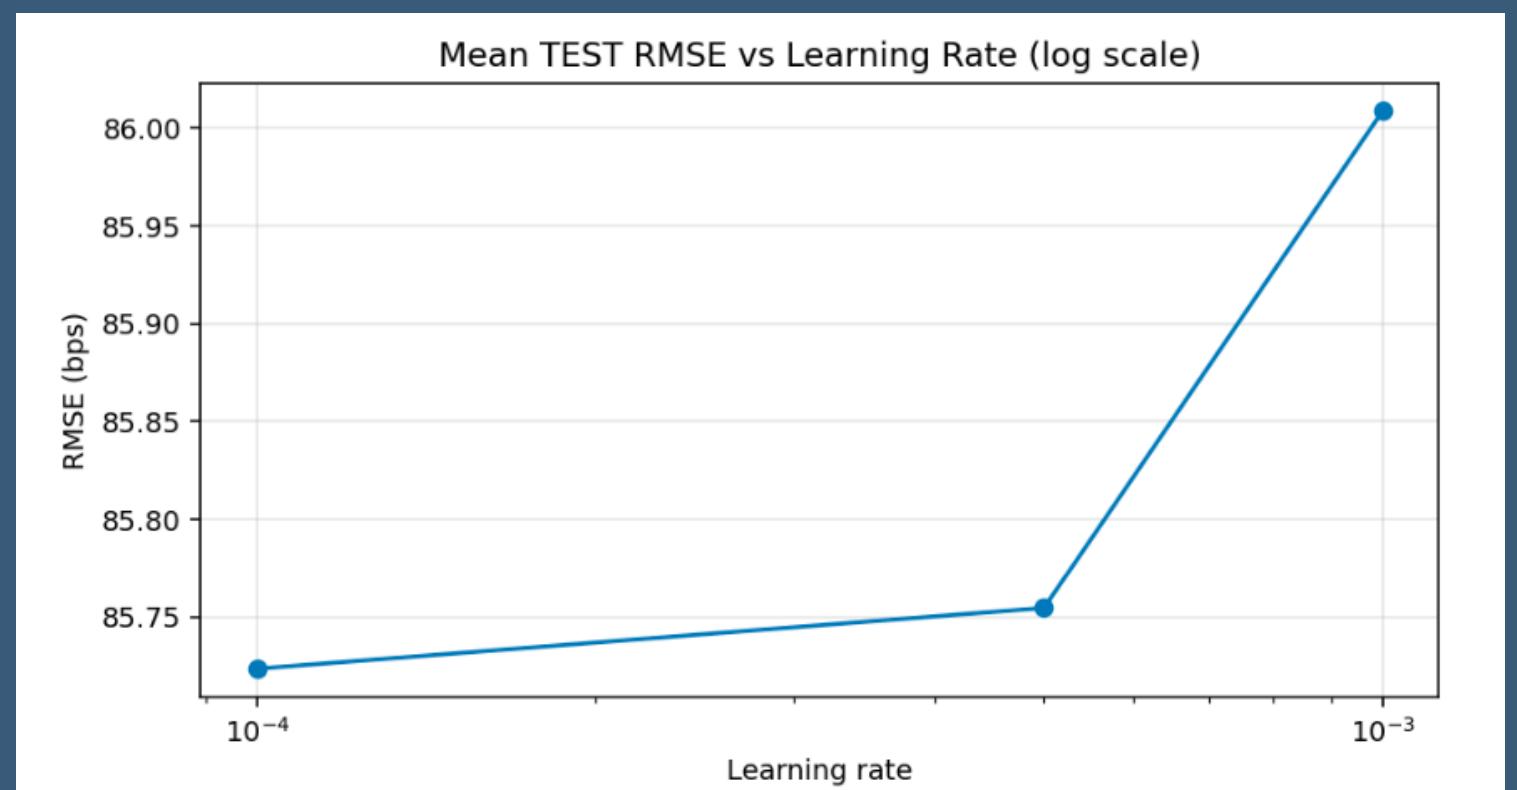
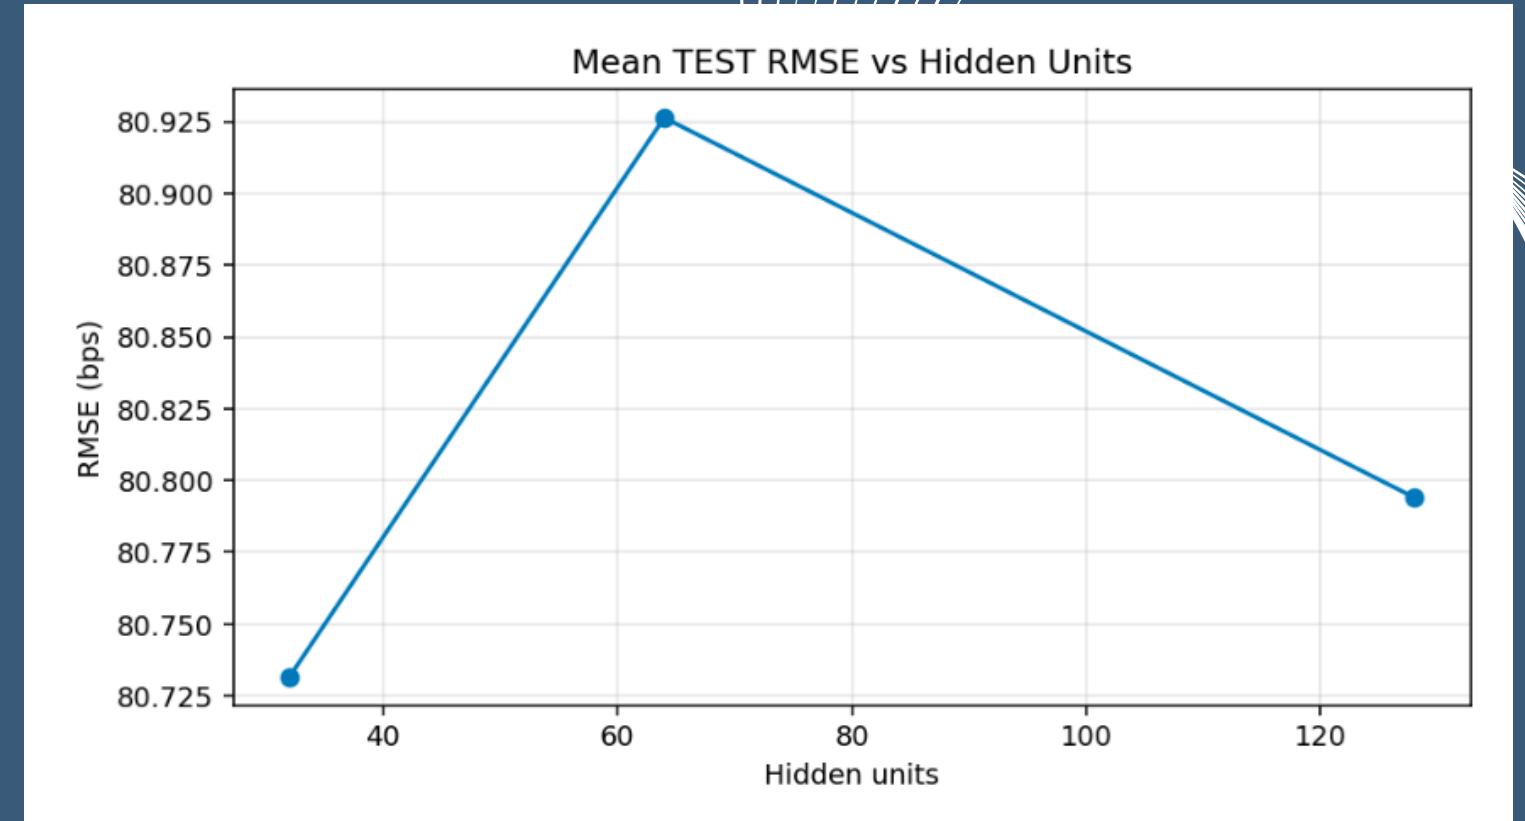
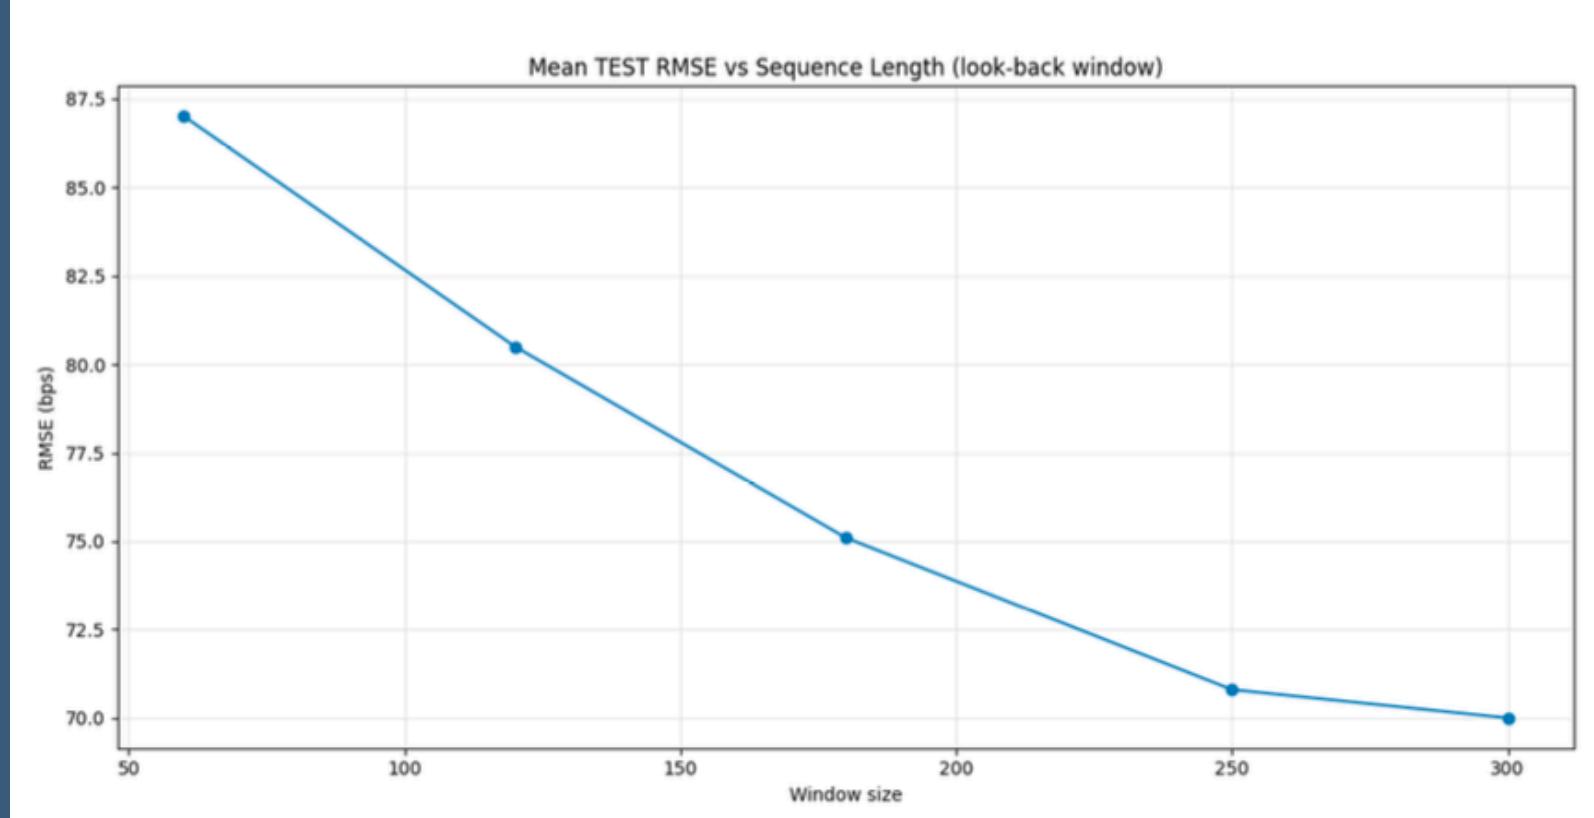
$$\hat{r}_{t+1} = f_{\text{LSTM}}(\mathbf{x}_{t-249:t})$$

# Fine-Tuning les hyperparamètres

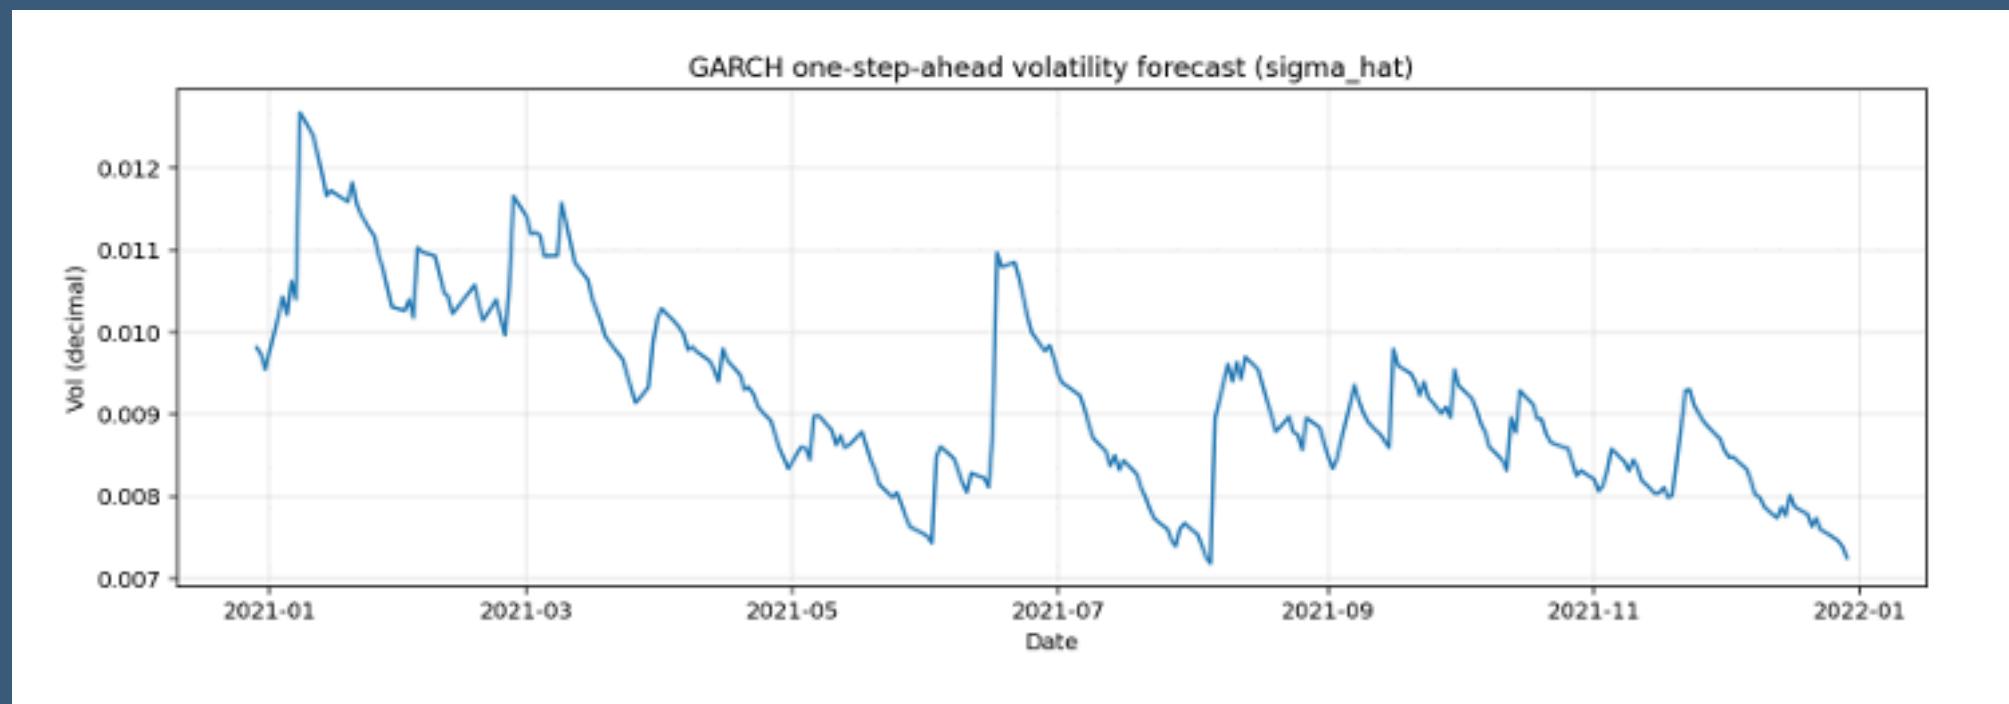
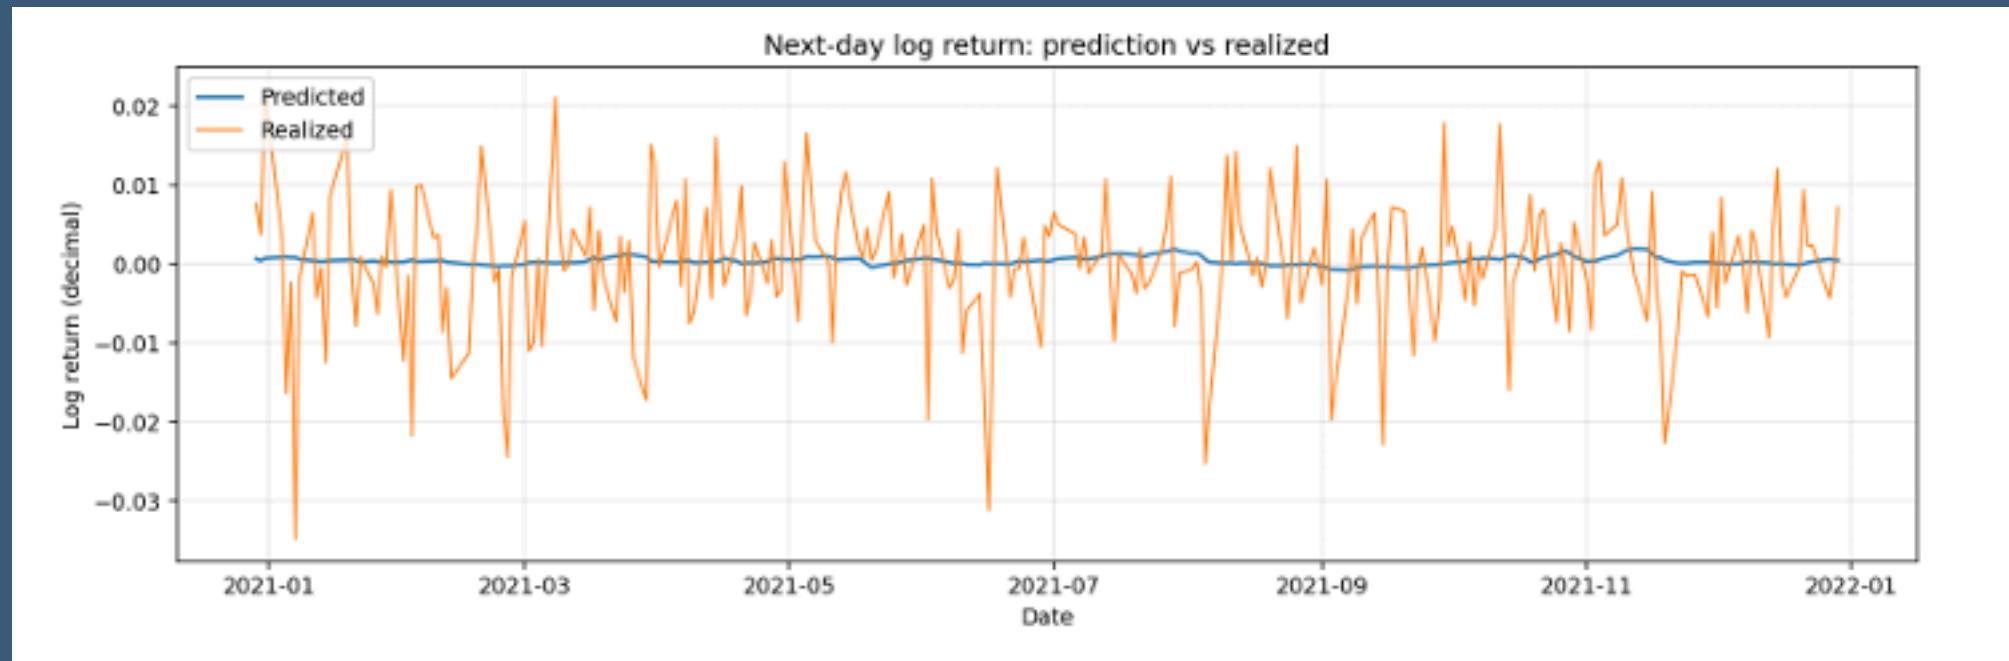
- Séparation en train/validation/test chronologique,  
1 année entière pour la validation
- Standardisation des inputs (train et test)

$$\tilde{\mathbf{x}}_t = \frac{\mathbf{x}_t - \mu_X}{\sigma_X}$$

$$\tilde{y}_t = \frac{y_t - \mu_y}{\sigma_y}$$



# Prédictions sur l'année 2021



## Pour les rendements (LSTM)

- Les prédictions sont lissées
- Le modèle capte surtout la direction, pas l'amplitude
- RMSE de 0.0184

## Pour la volatilité (GARCH)

- Clustering visible
  - Réversion graduelle vers une moyenne de long terme
- Signal directionnel et gestion du risque priment sur la précision des rendements.

# Stratégie de Trading



Lissage du signal (LSTM)

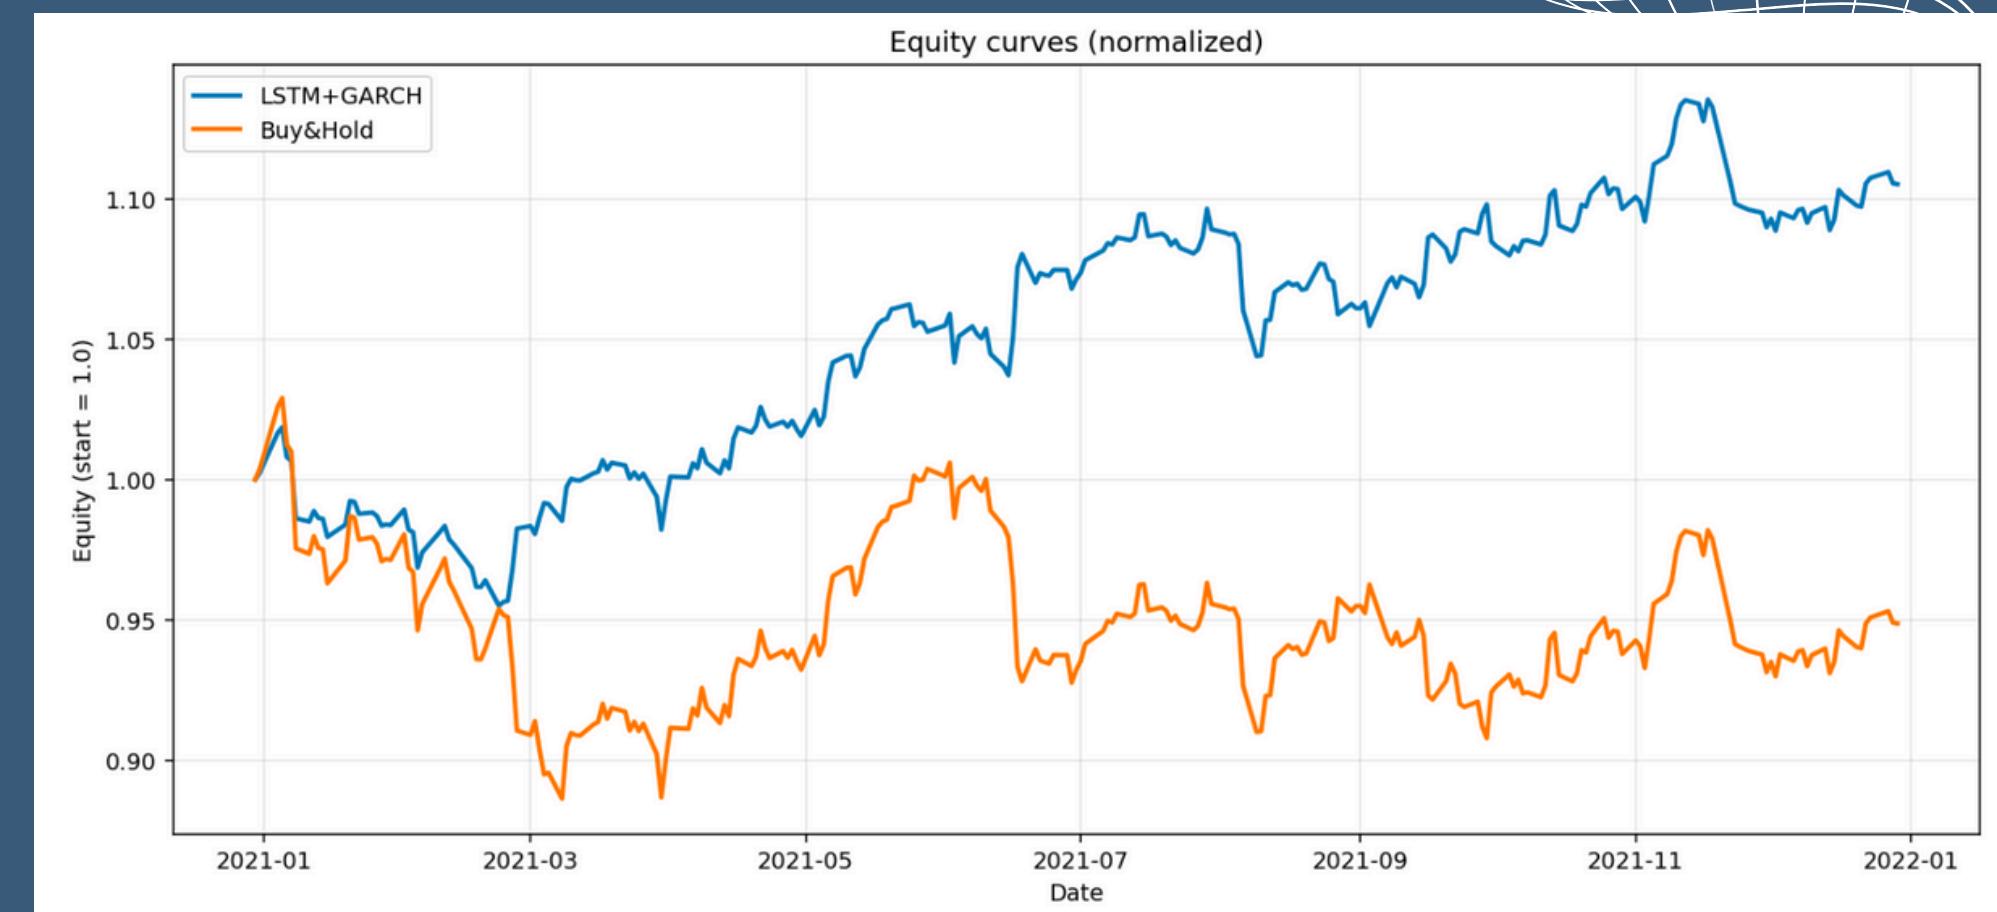
$$\bar{r}_t = \frac{1}{H} \sum_{j=0}^{H-1} \hat{r}_{t-j} \rightarrow s_t = \text{sign}(\bar{r}_t)$$

Poids (GARCH)

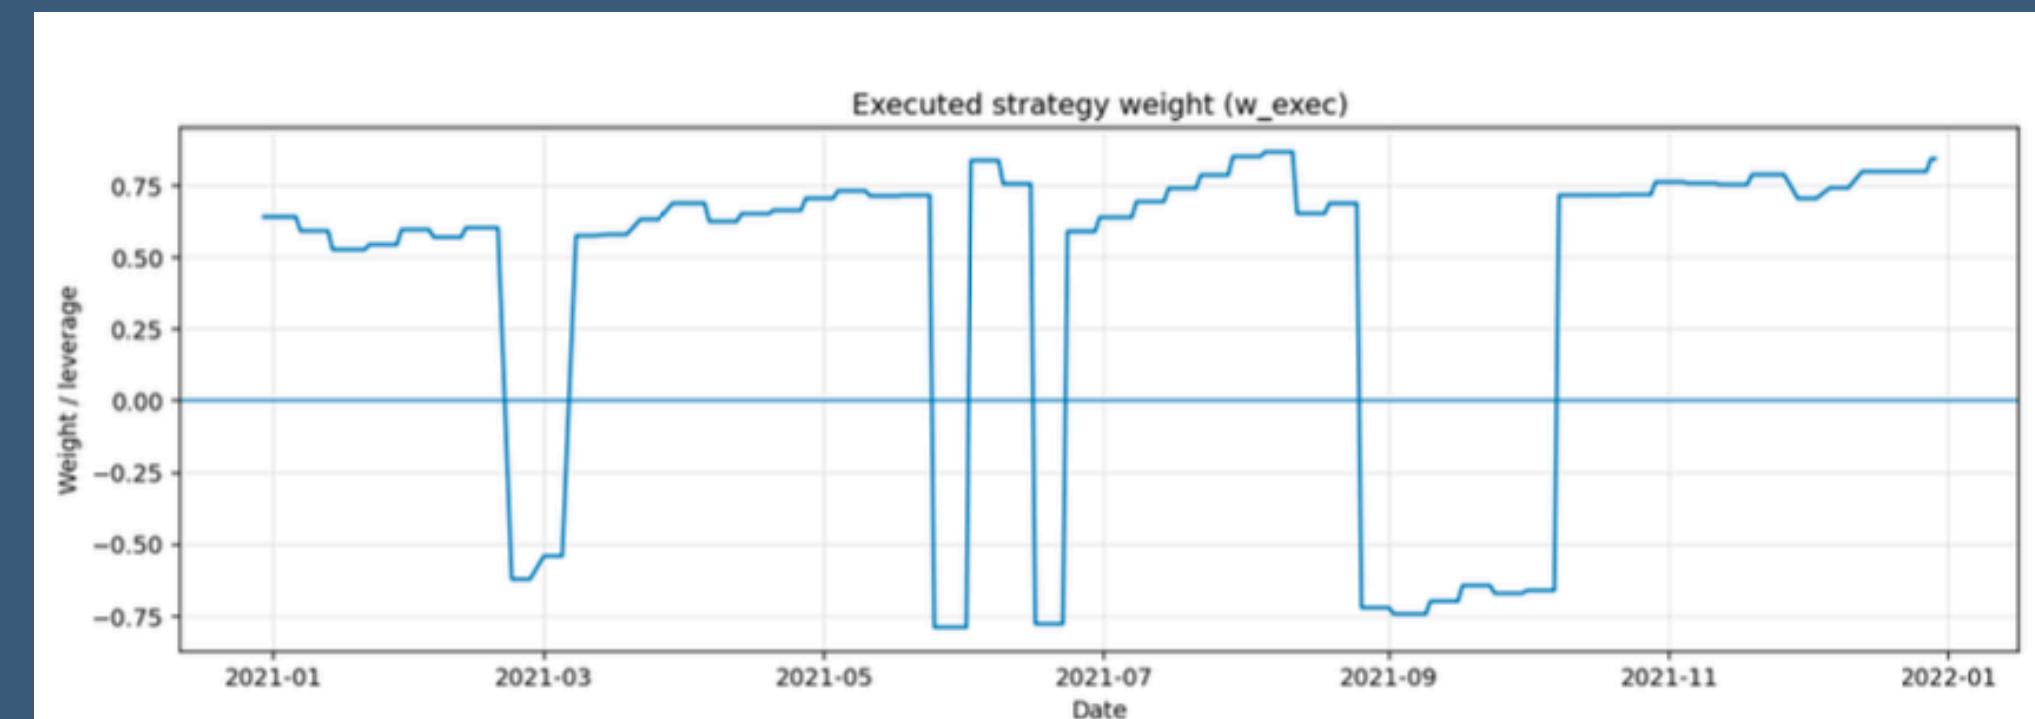
$$w_t = \frac{1}{\hat{\sigma}_t} \rightarrow w_t^* = \frac{\sigma^*}{\hat{\sigma}_t} s_t$$

Le LSTM (la prédiction) guide la direction, le GARCH contrôle l'exposition au risque

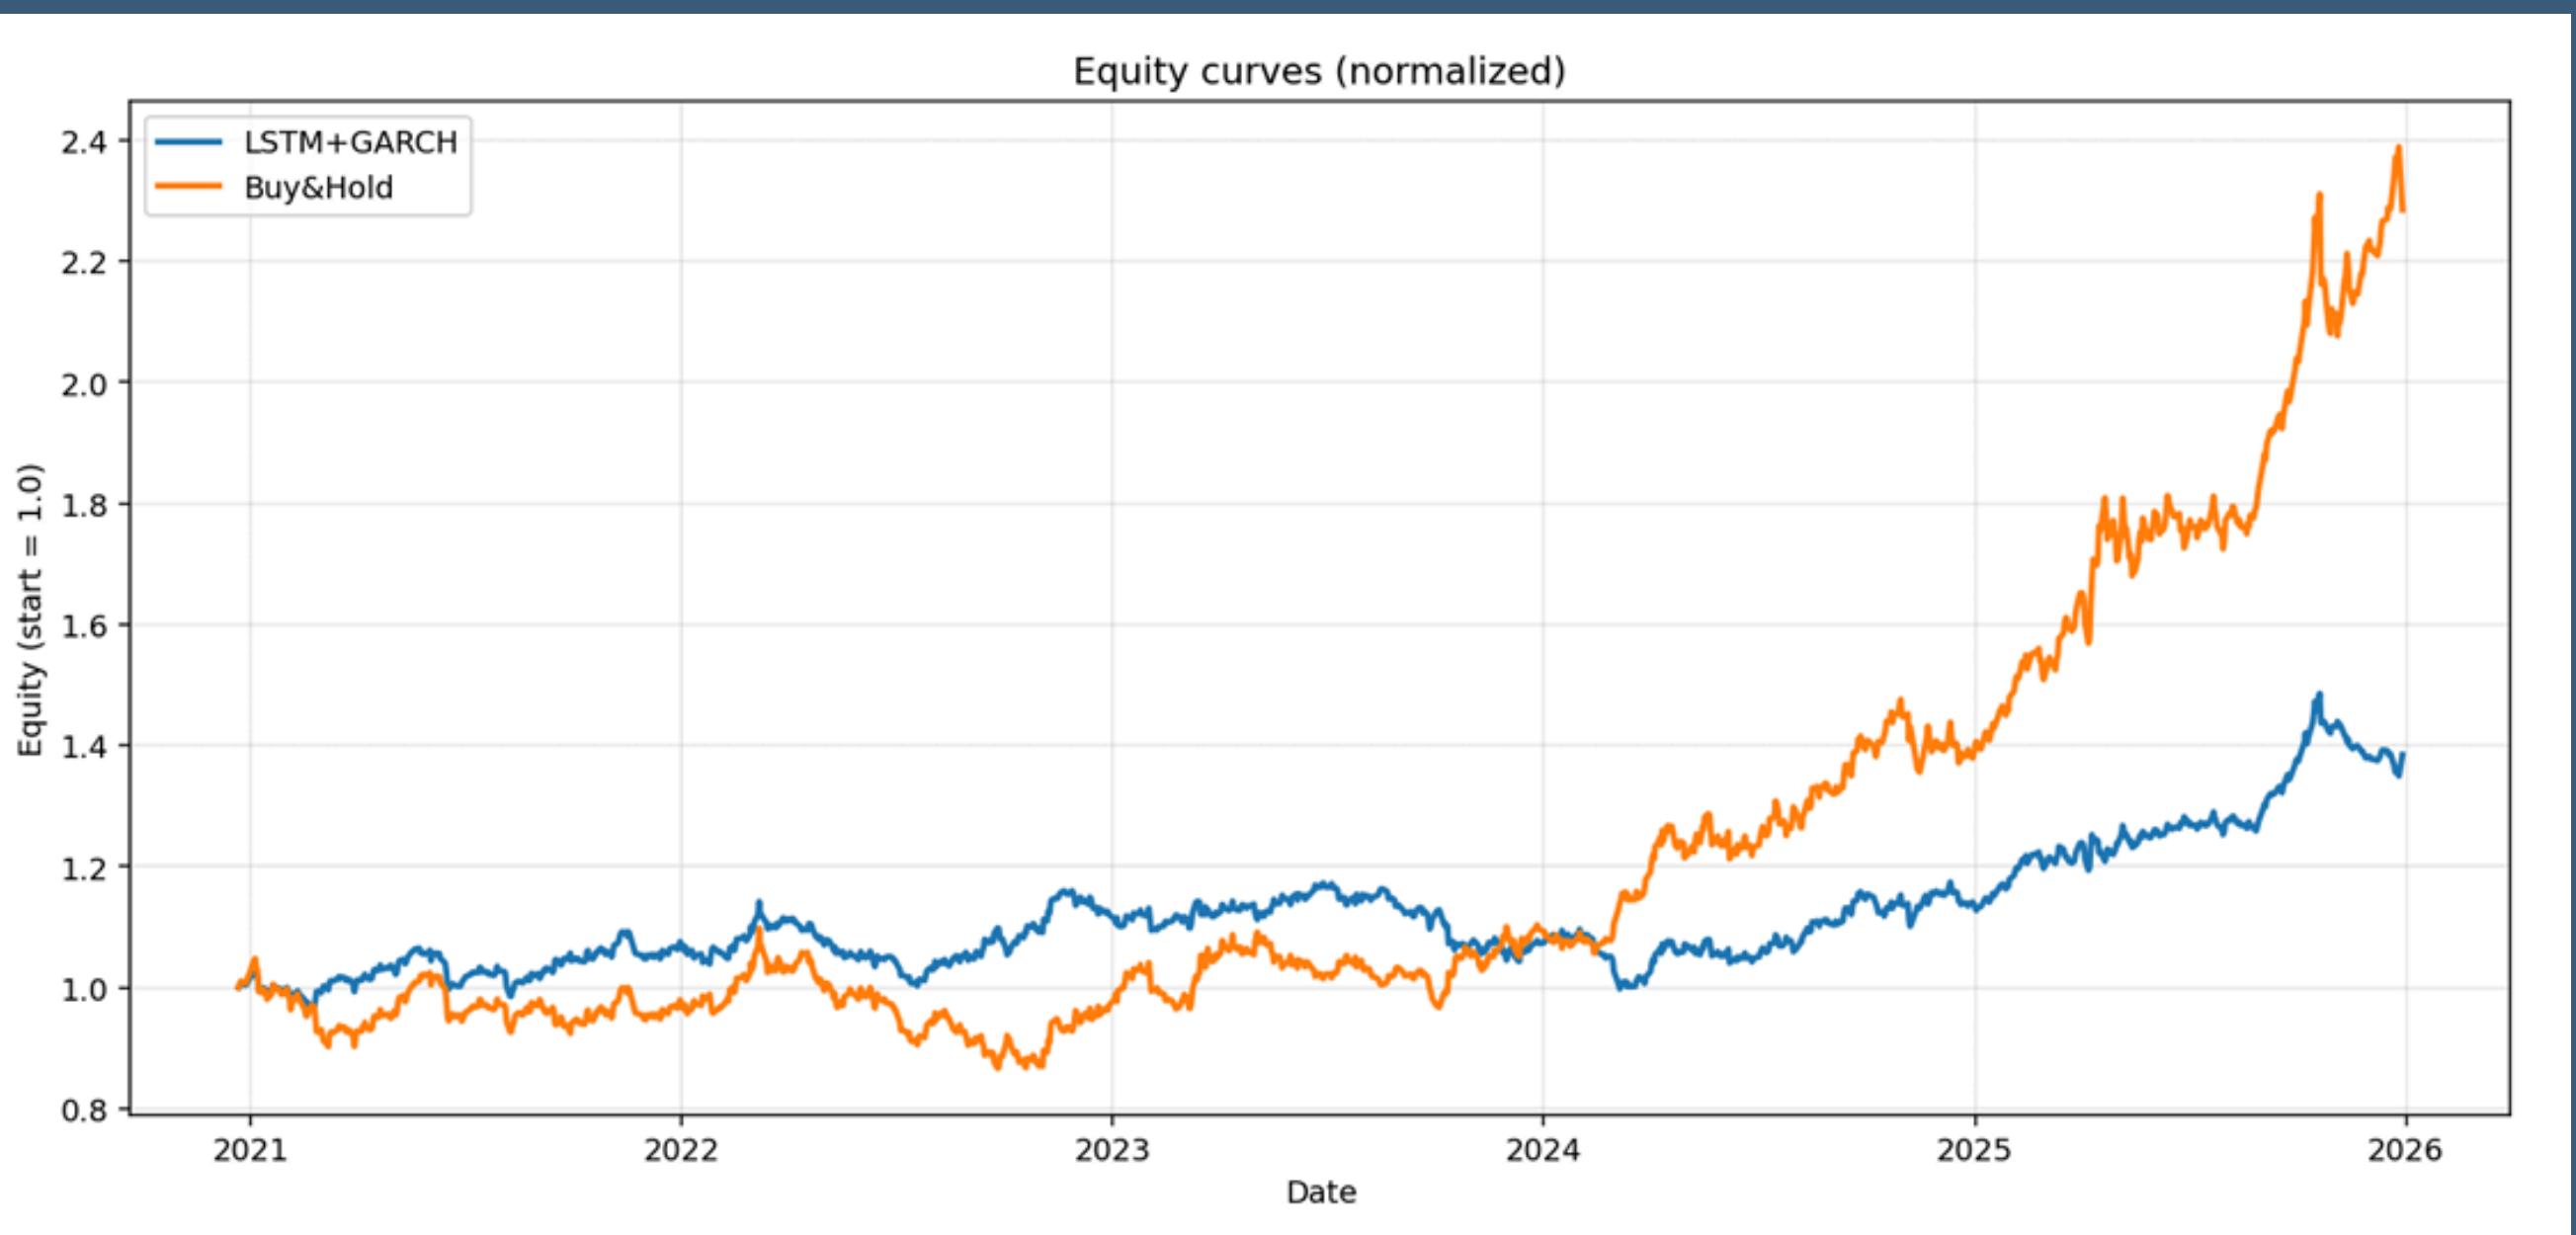
Signal Long/Short



Poids Long/Short



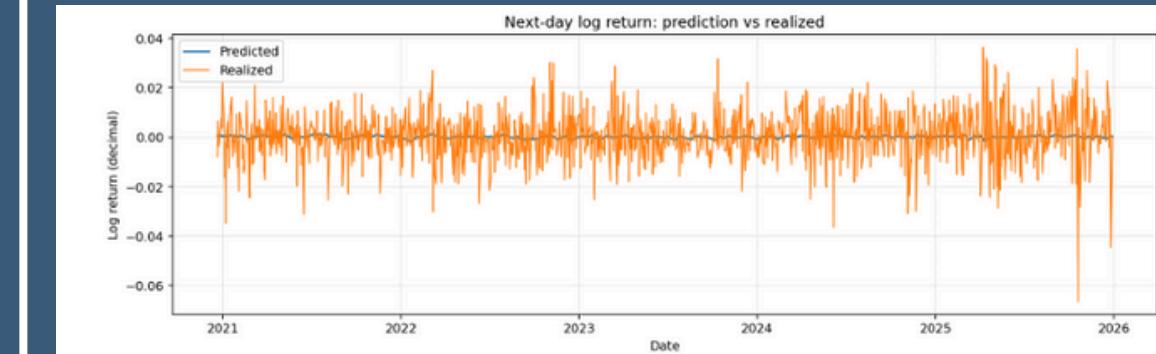
# Stratégies benchmark et évaluation (2021-2025)



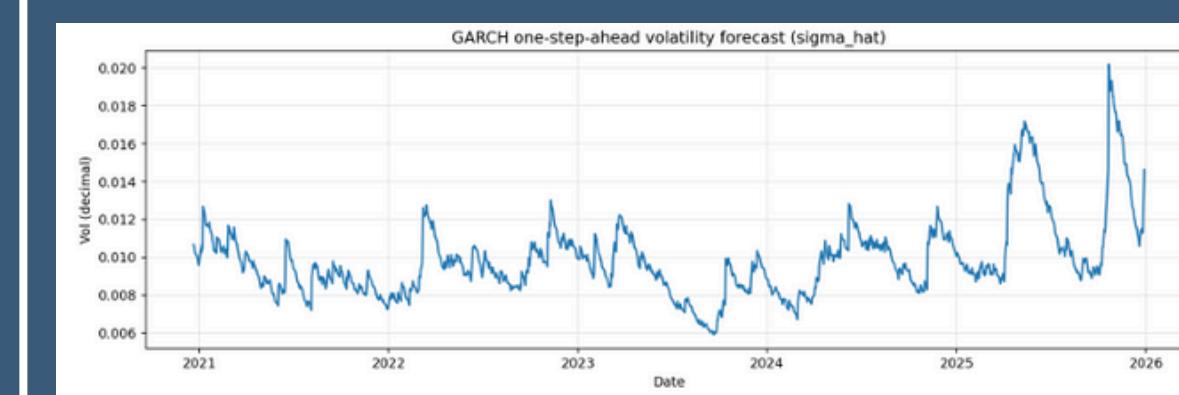
**Table 2.1:** Five-year (2021-2025) average performance of the LSTM+GARCH strategy across rolling test windows.

Metric	CAGR (%)	Ann Vol (%)	Sharpe	Max DD (%)	Total Tcost (\$)
<b>5-year average</b>	11.25	10.09	1.09	-7.22	192,305

Note: Each test window spans approximately one trading year; hence CAGR coincides with annual return in the reported averages.

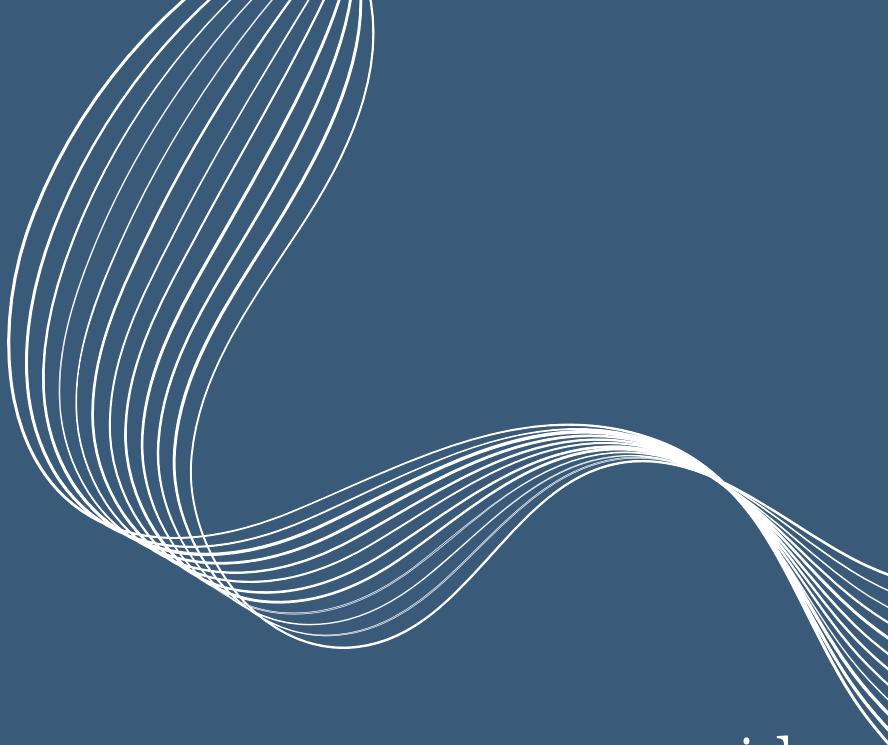


**Figure 2.8:** Next-day log-return forecasts compared with realized returns. While predicted returns remain close to zero, realized returns display large fluctuations, highlighting the difficulty of short-horizon return prediction despite time-varying volatility.



**Figure 2.7:** One-step-ahead conditional volatility forecasts  $\hat{\sigma}_{t+1}$  from the GARCH model. The series exhibits pronounced volatility clustering, with sharp spikes during periods of market stress, particularly toward the end of the sample.

# Gradient Boosting - XGBoost



- Combiner la structure statistique et la flexibilité du ML
- Objectif : Estimer la fonction de régression par minimisation itérative du risque empirique.

$$f(x) = \mathbb{E}[Y | X = x]$$

- Algorithme : Somme pondérée d'apprenants faibles (arbres de régression)

$$\hat{f}(x) = \sum_{m=1}^M \beta_m h_m(x)$$

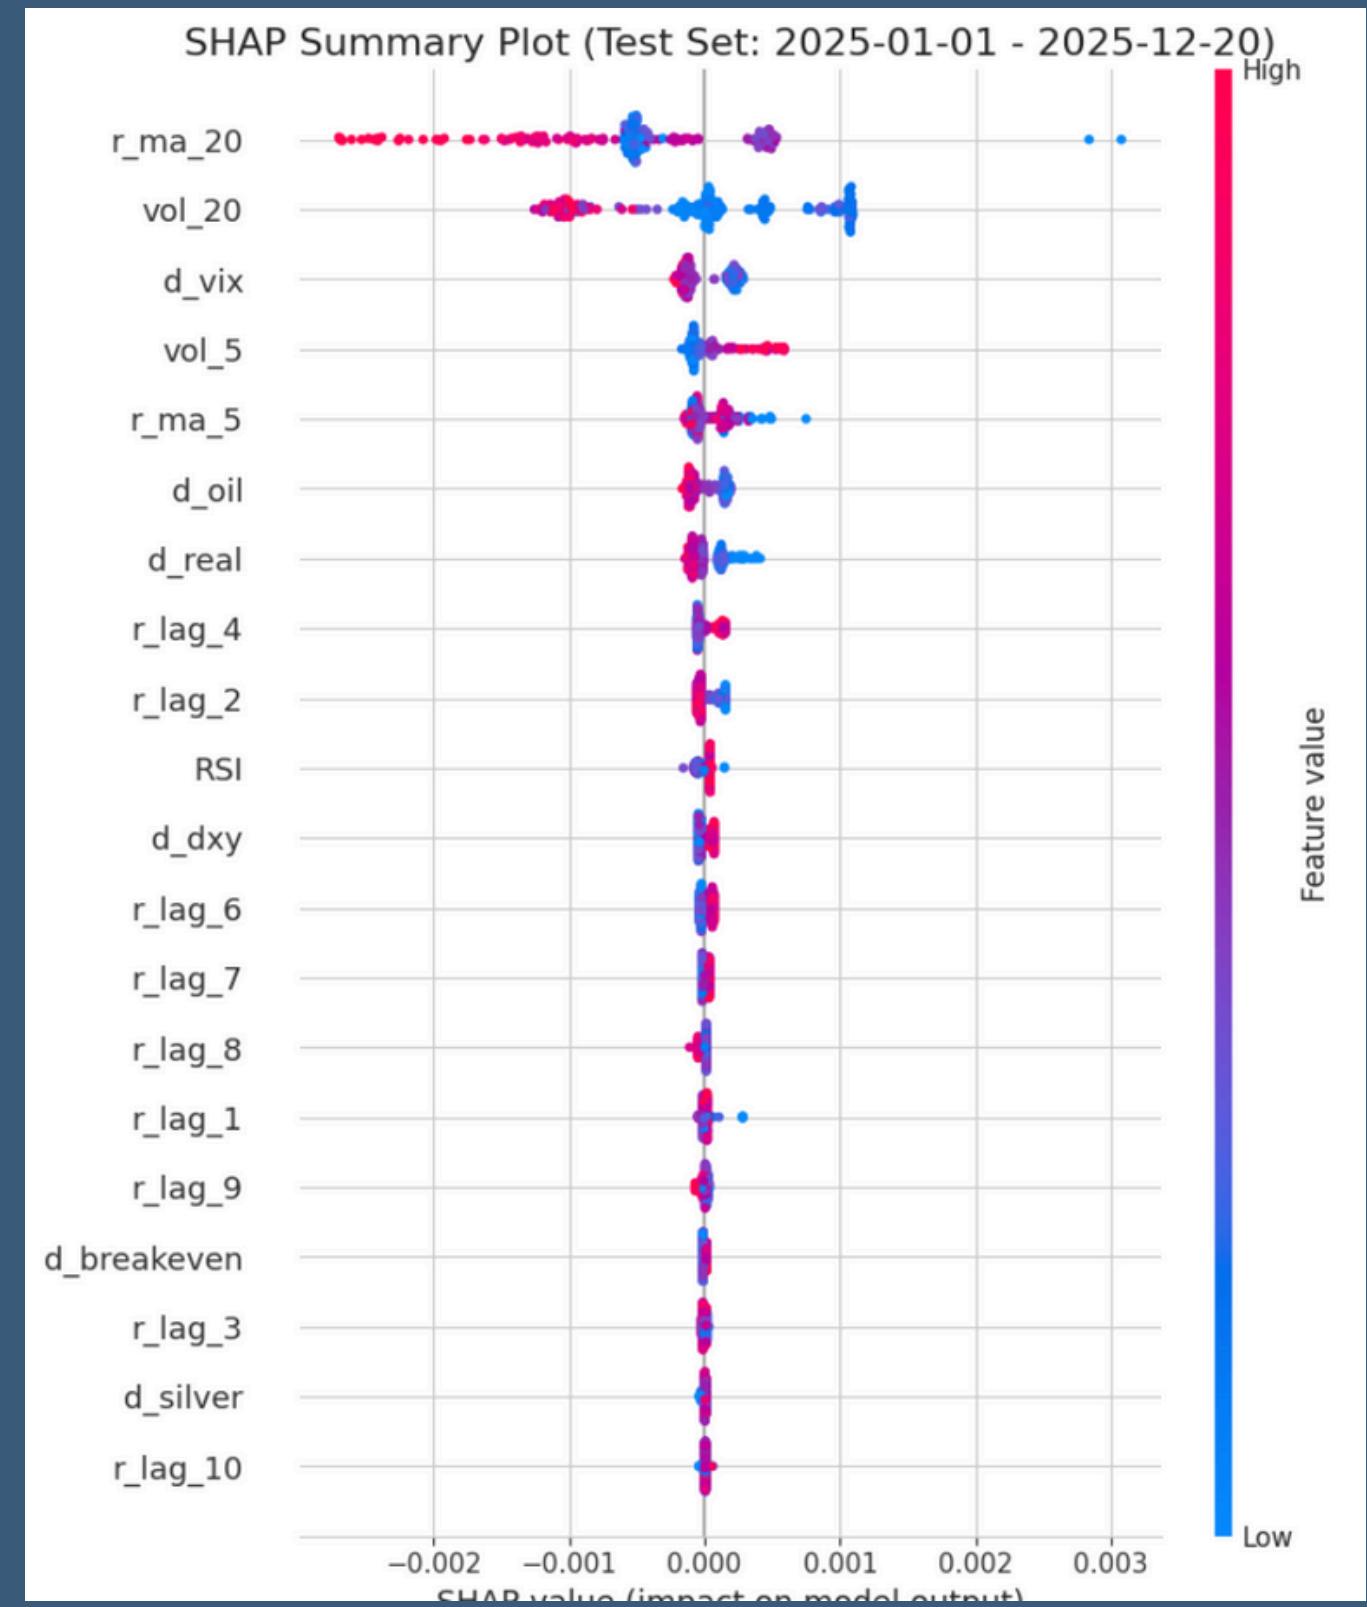
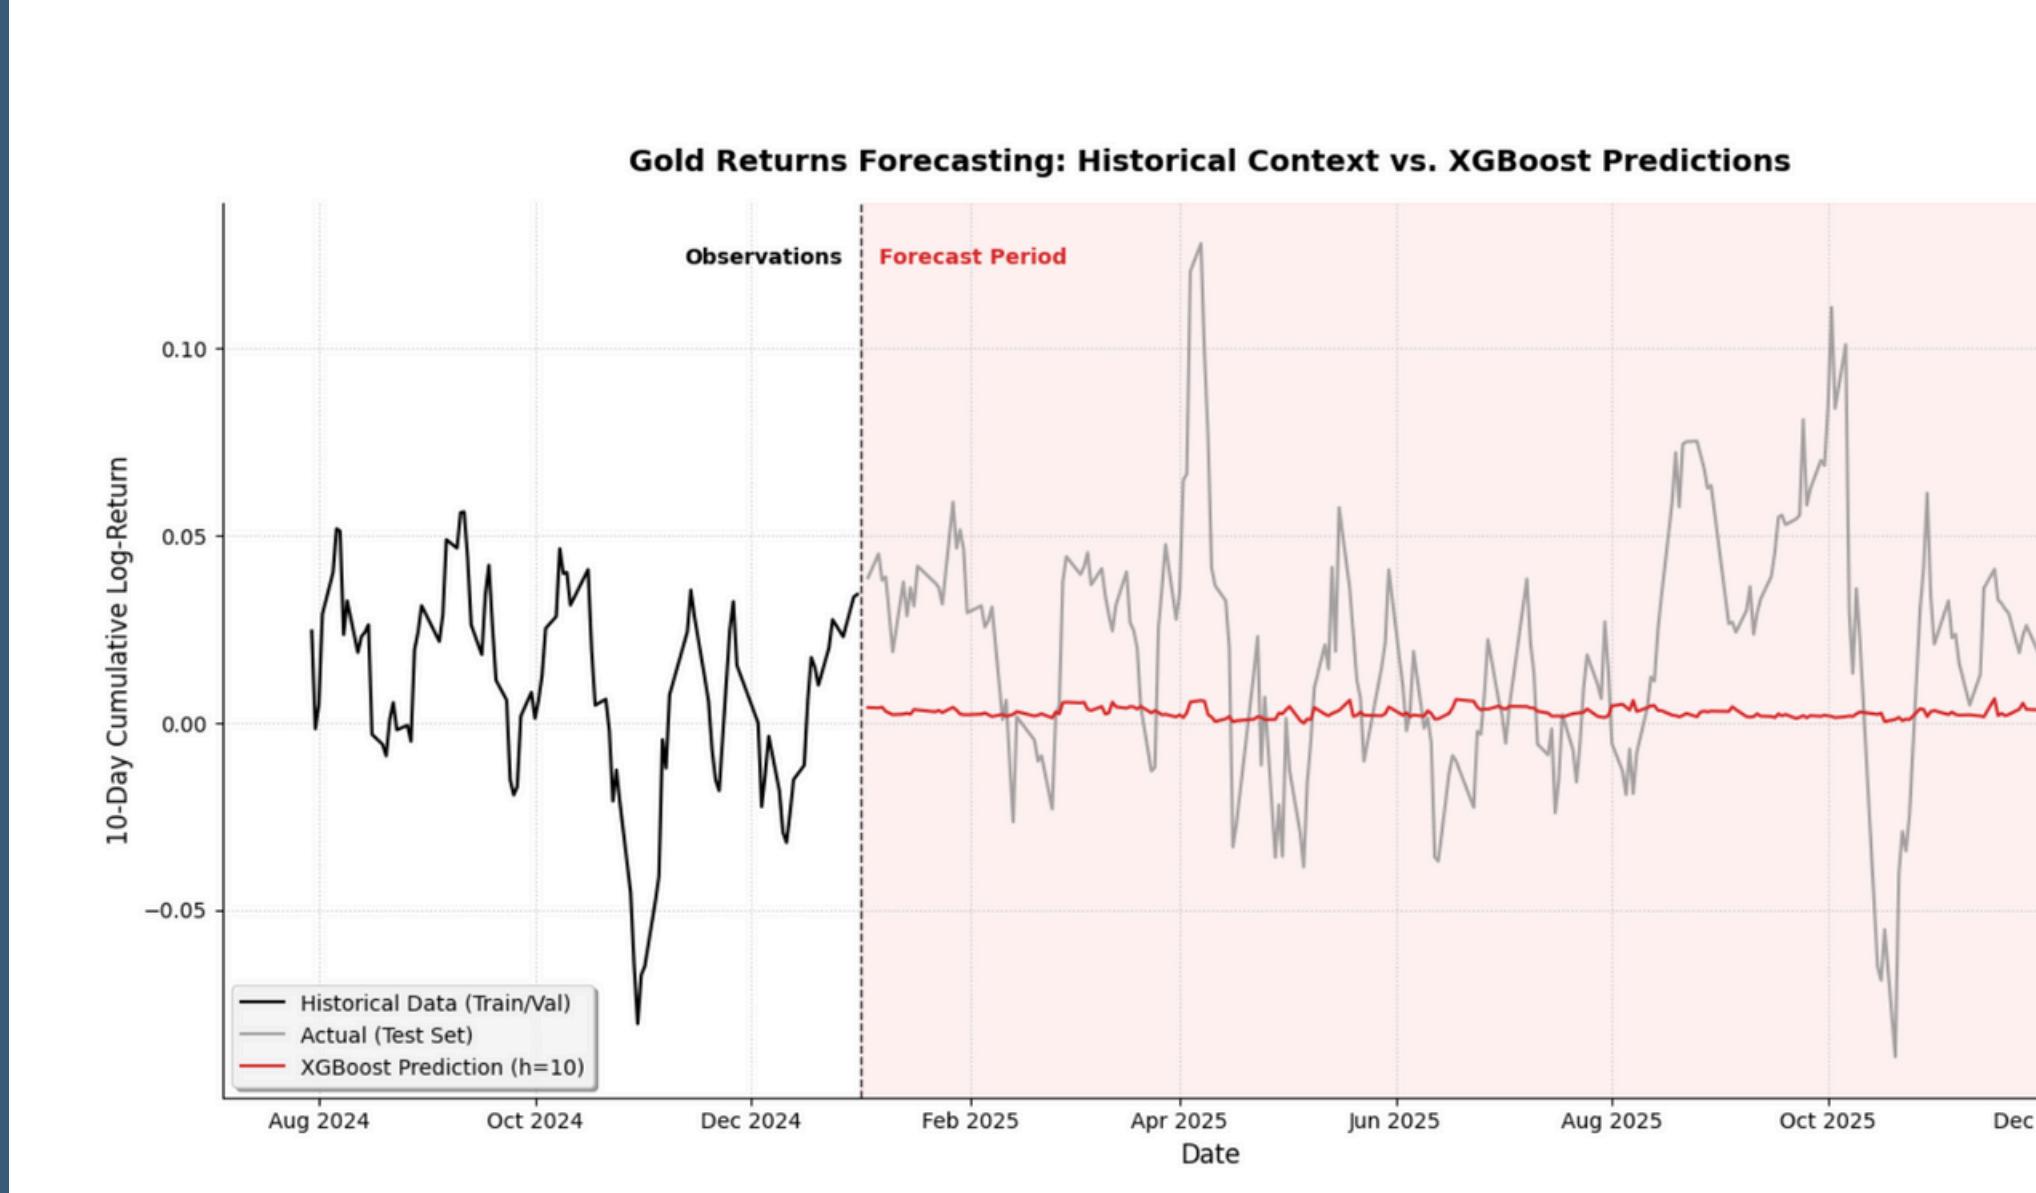
- XGBoost :

Approximation du second ordre pour une convergence rapide  
+  
Régularisation explicite pour contrôler la complexité

- Cible : prédiction cumulée à 10 jours pour augmenter le ratio signa-bruit

$$y_t^{(h)} = \sum_{k=1}^h r_{t+k}, \quad \text{with } h = 10$$

# Résultats: un modèle XGBoost avec facteurs exogènes



*Predictions cumulatives du modèle XGBoost à horizon  $h=10$*

→ Directional Accuracy : **76.11%**

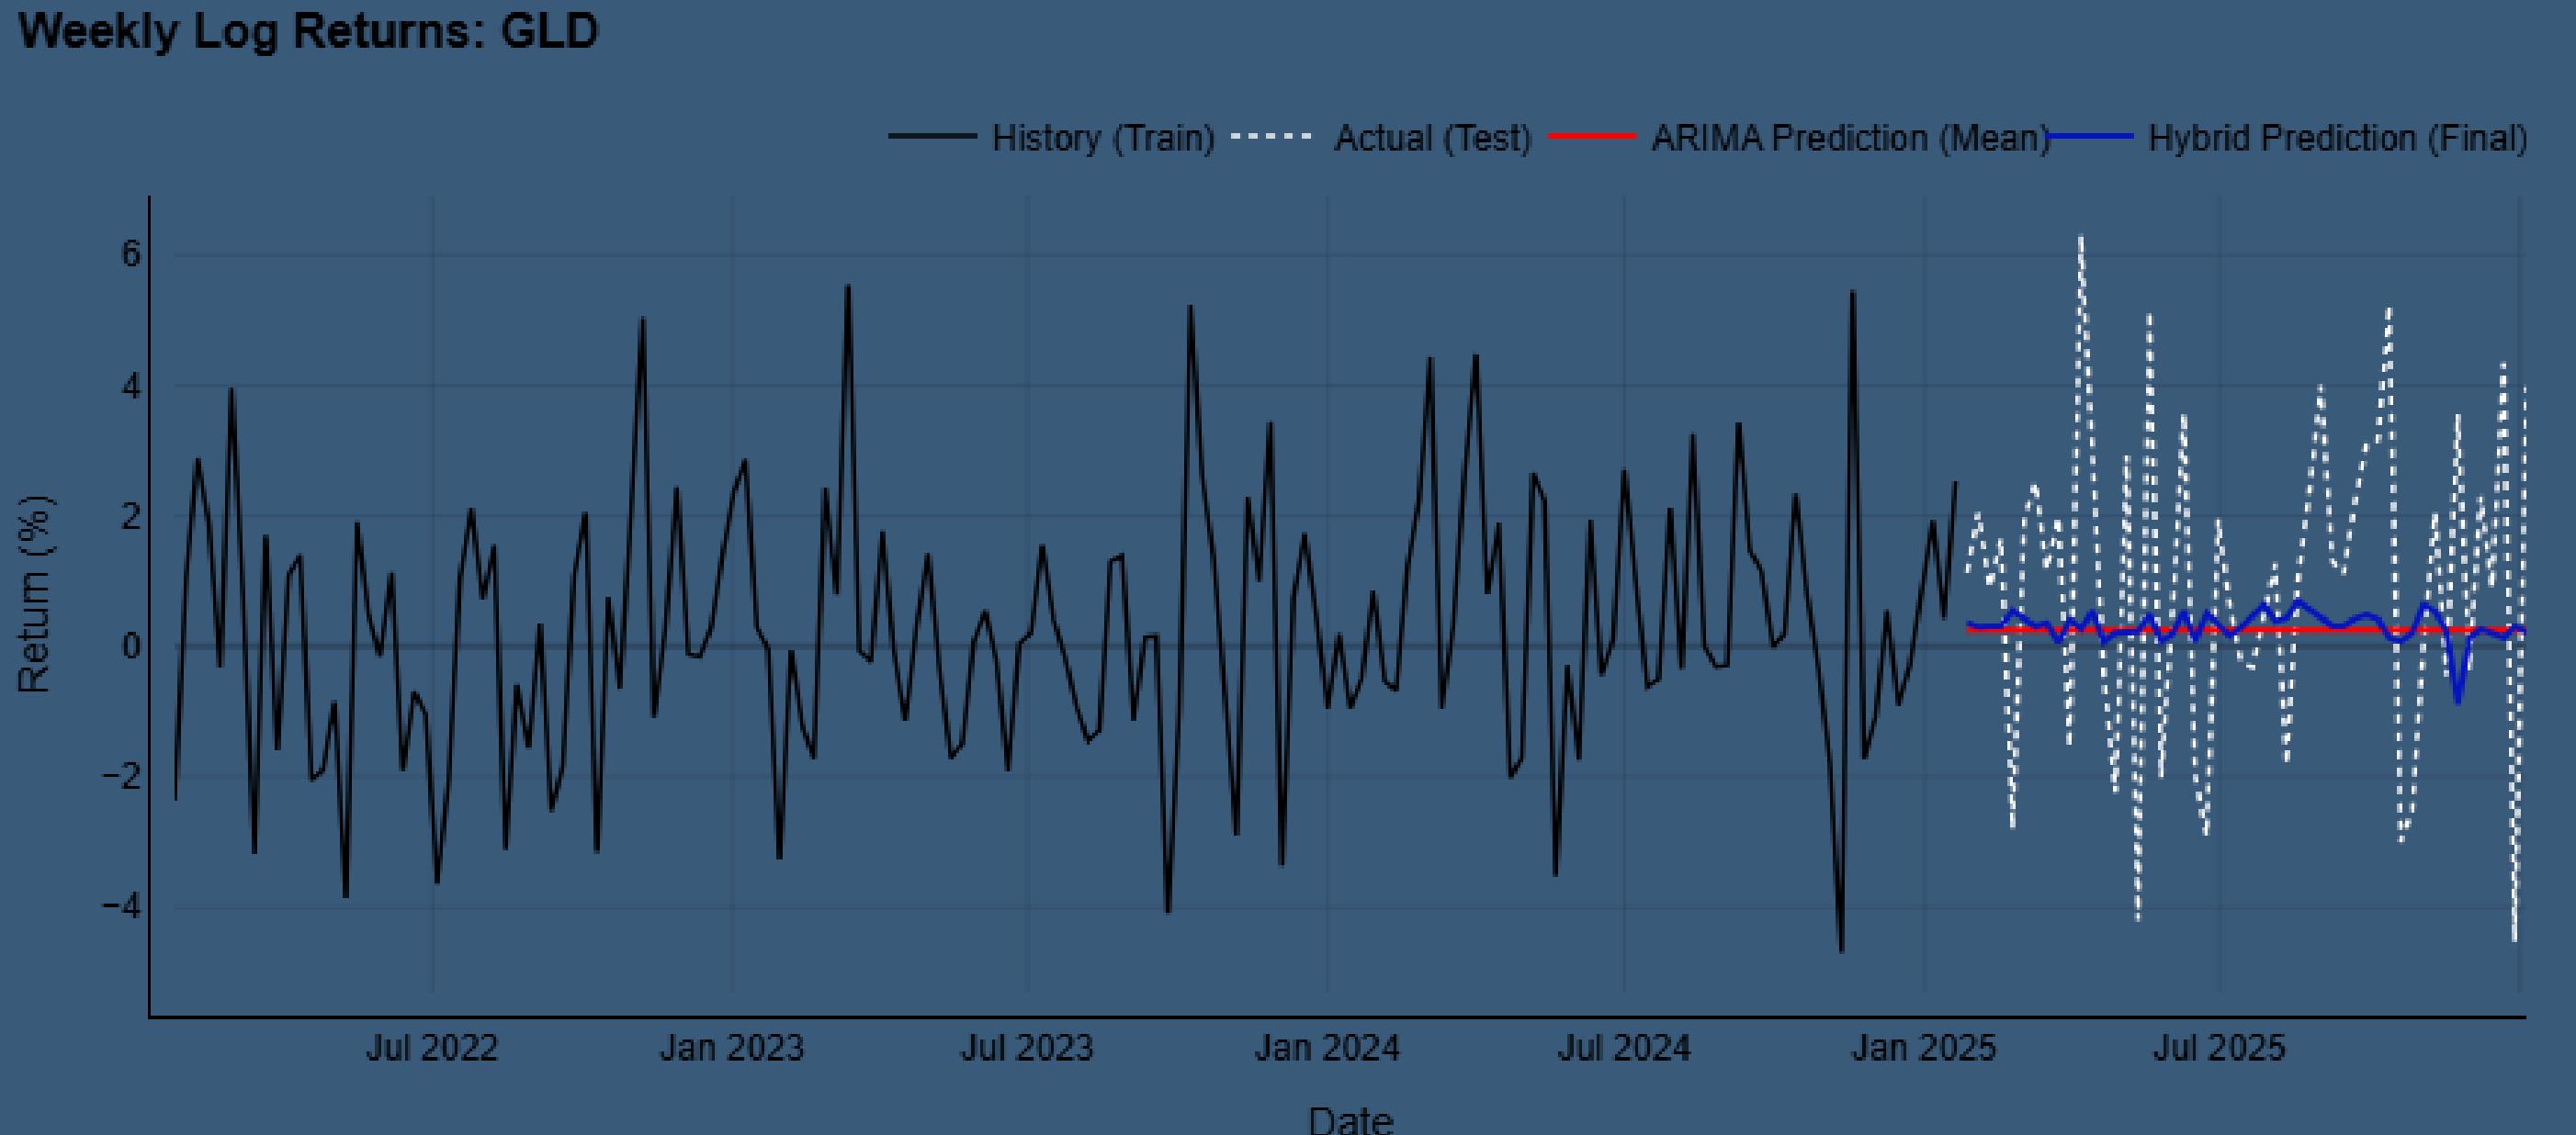
→ Faible baisse du RMSE par rapport au modèle naïf

→ Suivi de tendance conservateur

*Analyse des SHAP values*

# Modèle hybride vs ARIMA simple

- Prédire la tendance avec ARIMA sur les 3 dernières années
- Utiliser XGBoost (avec indicateur macro et technique) pour prédire les erreurs futures de ARIMA → modèle hybride  
ARIMA - XGBoost

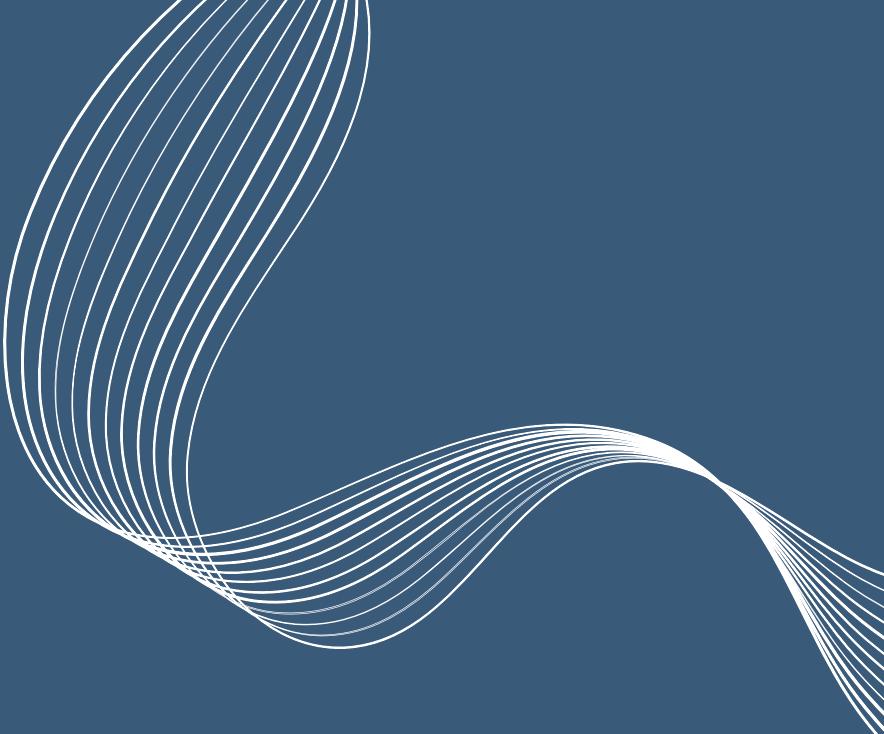


# Modèle hybride vs ARIMA simple

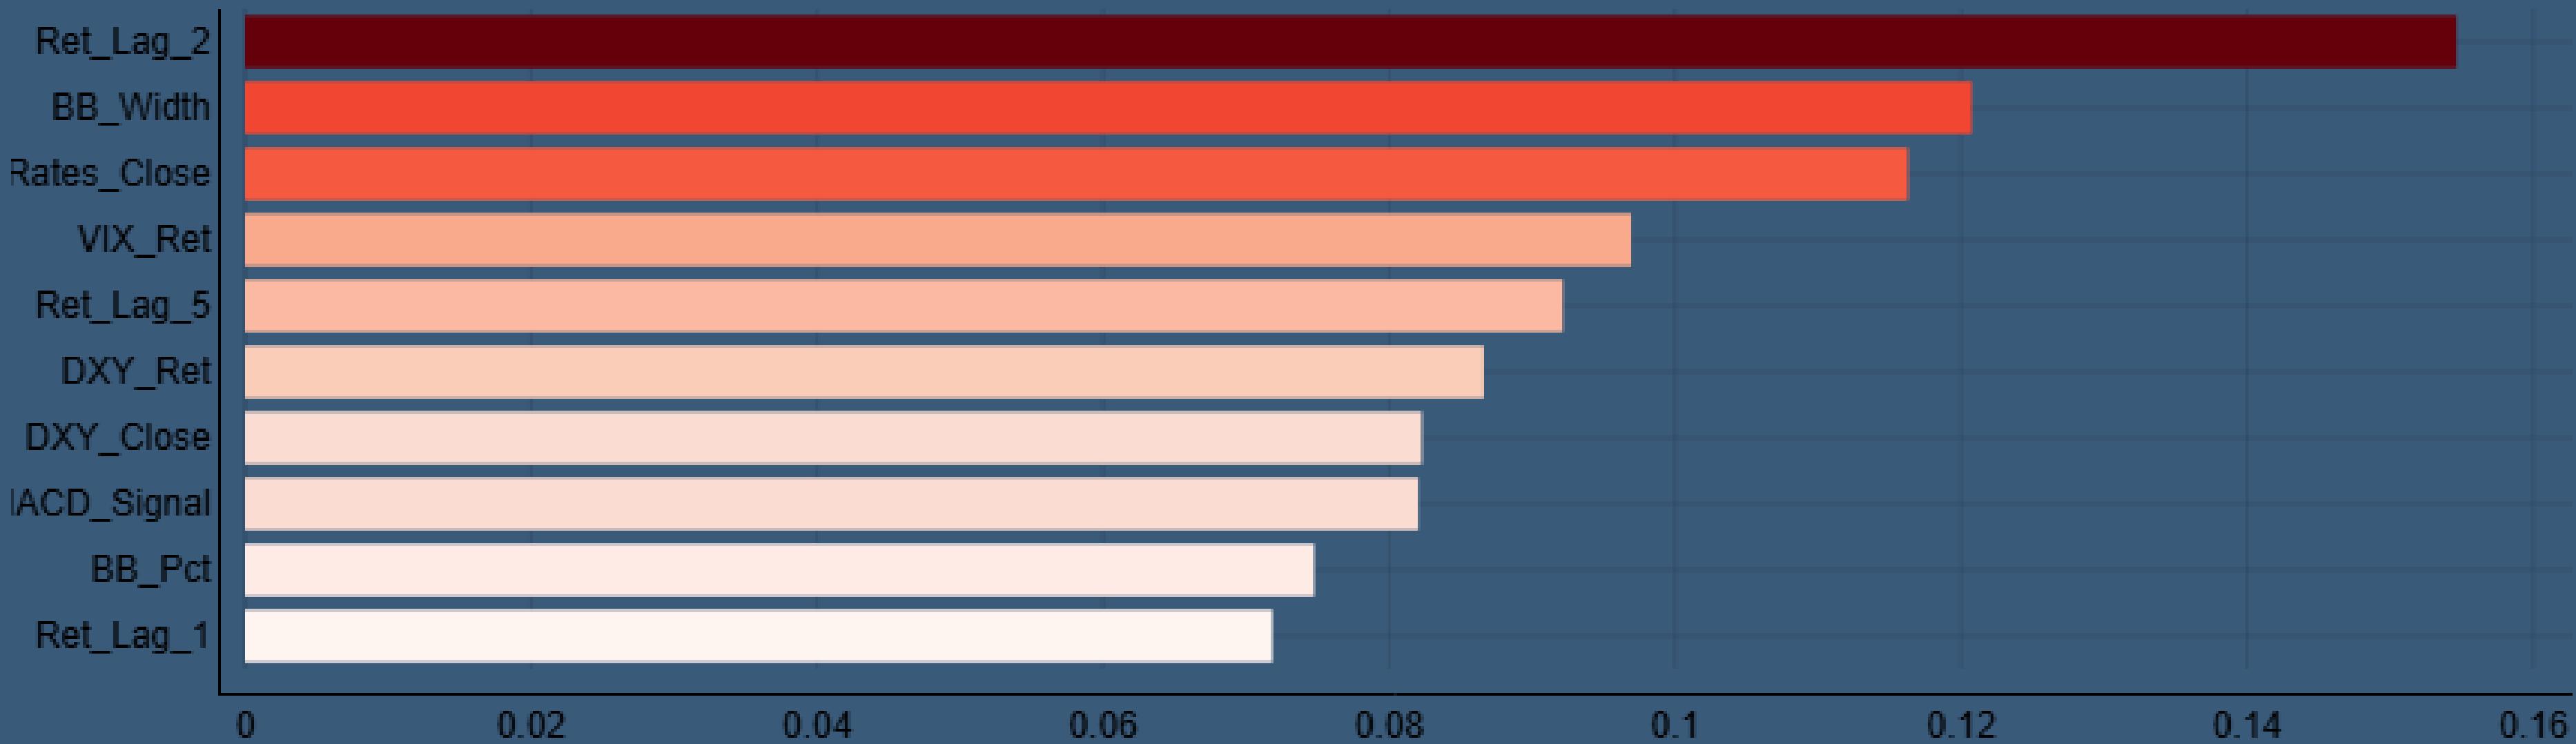
Long-Term Simulation: GLD



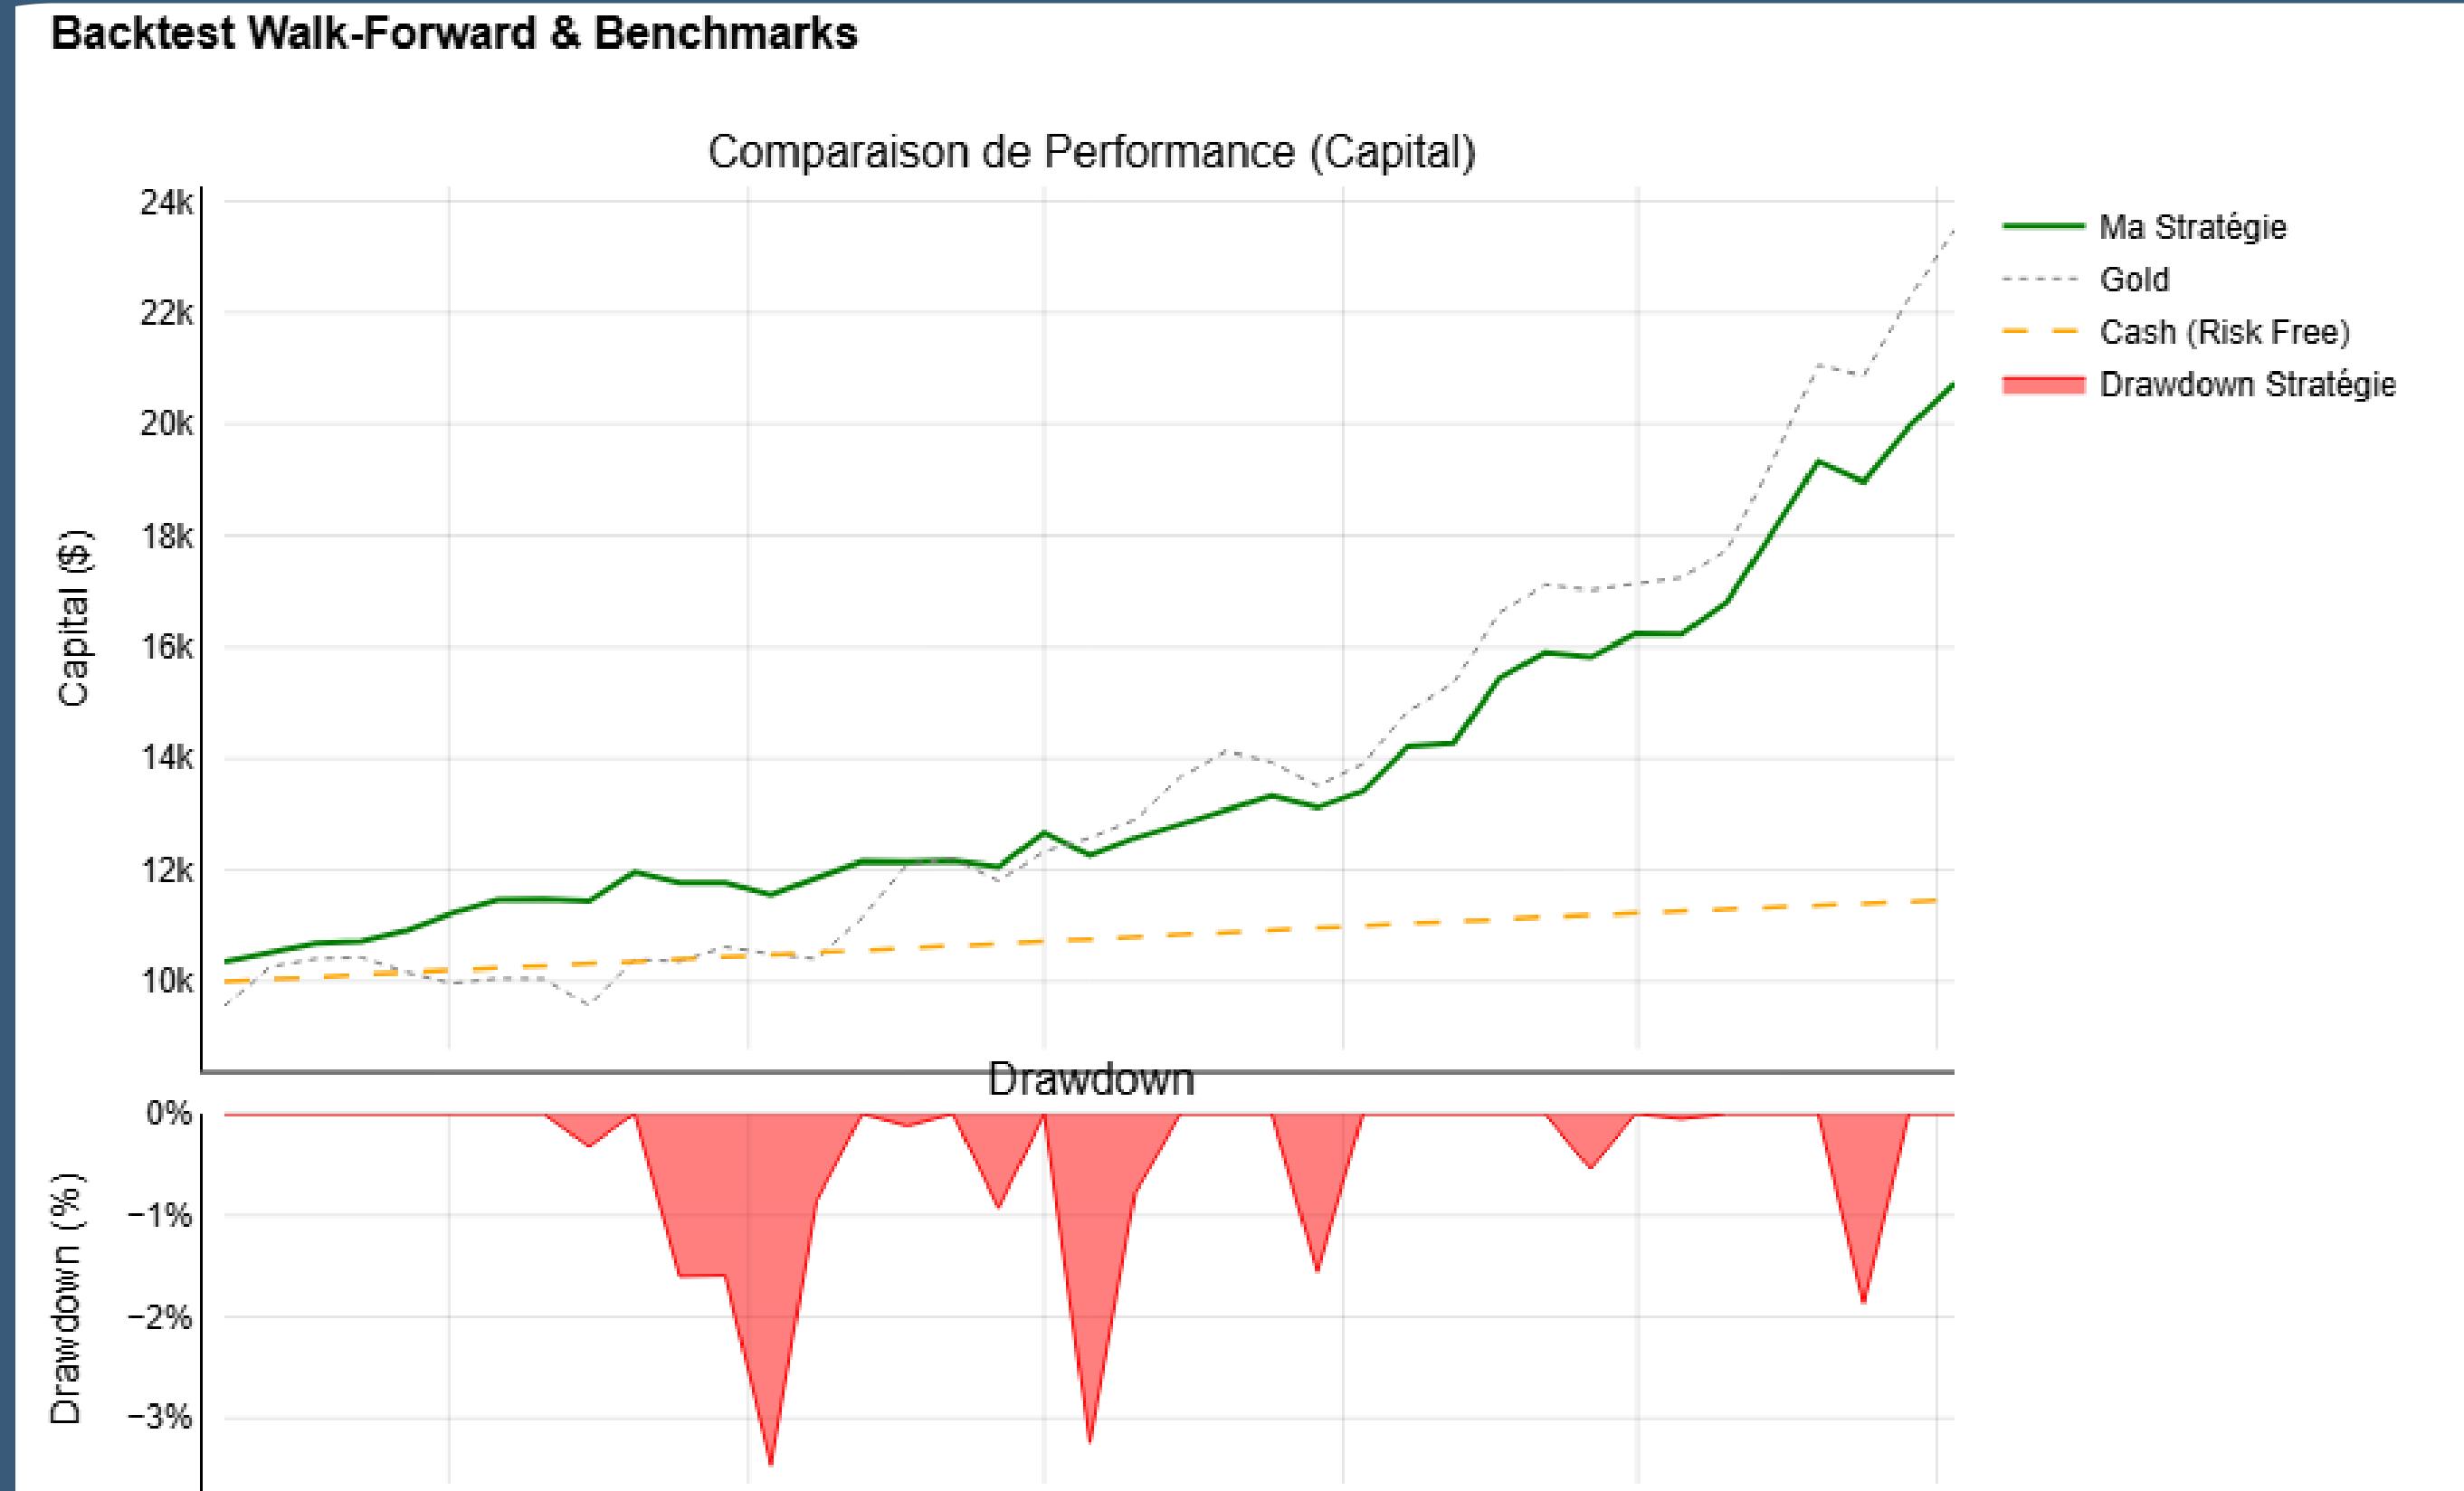
# Importance des features



Feature Importance (XGBoost)

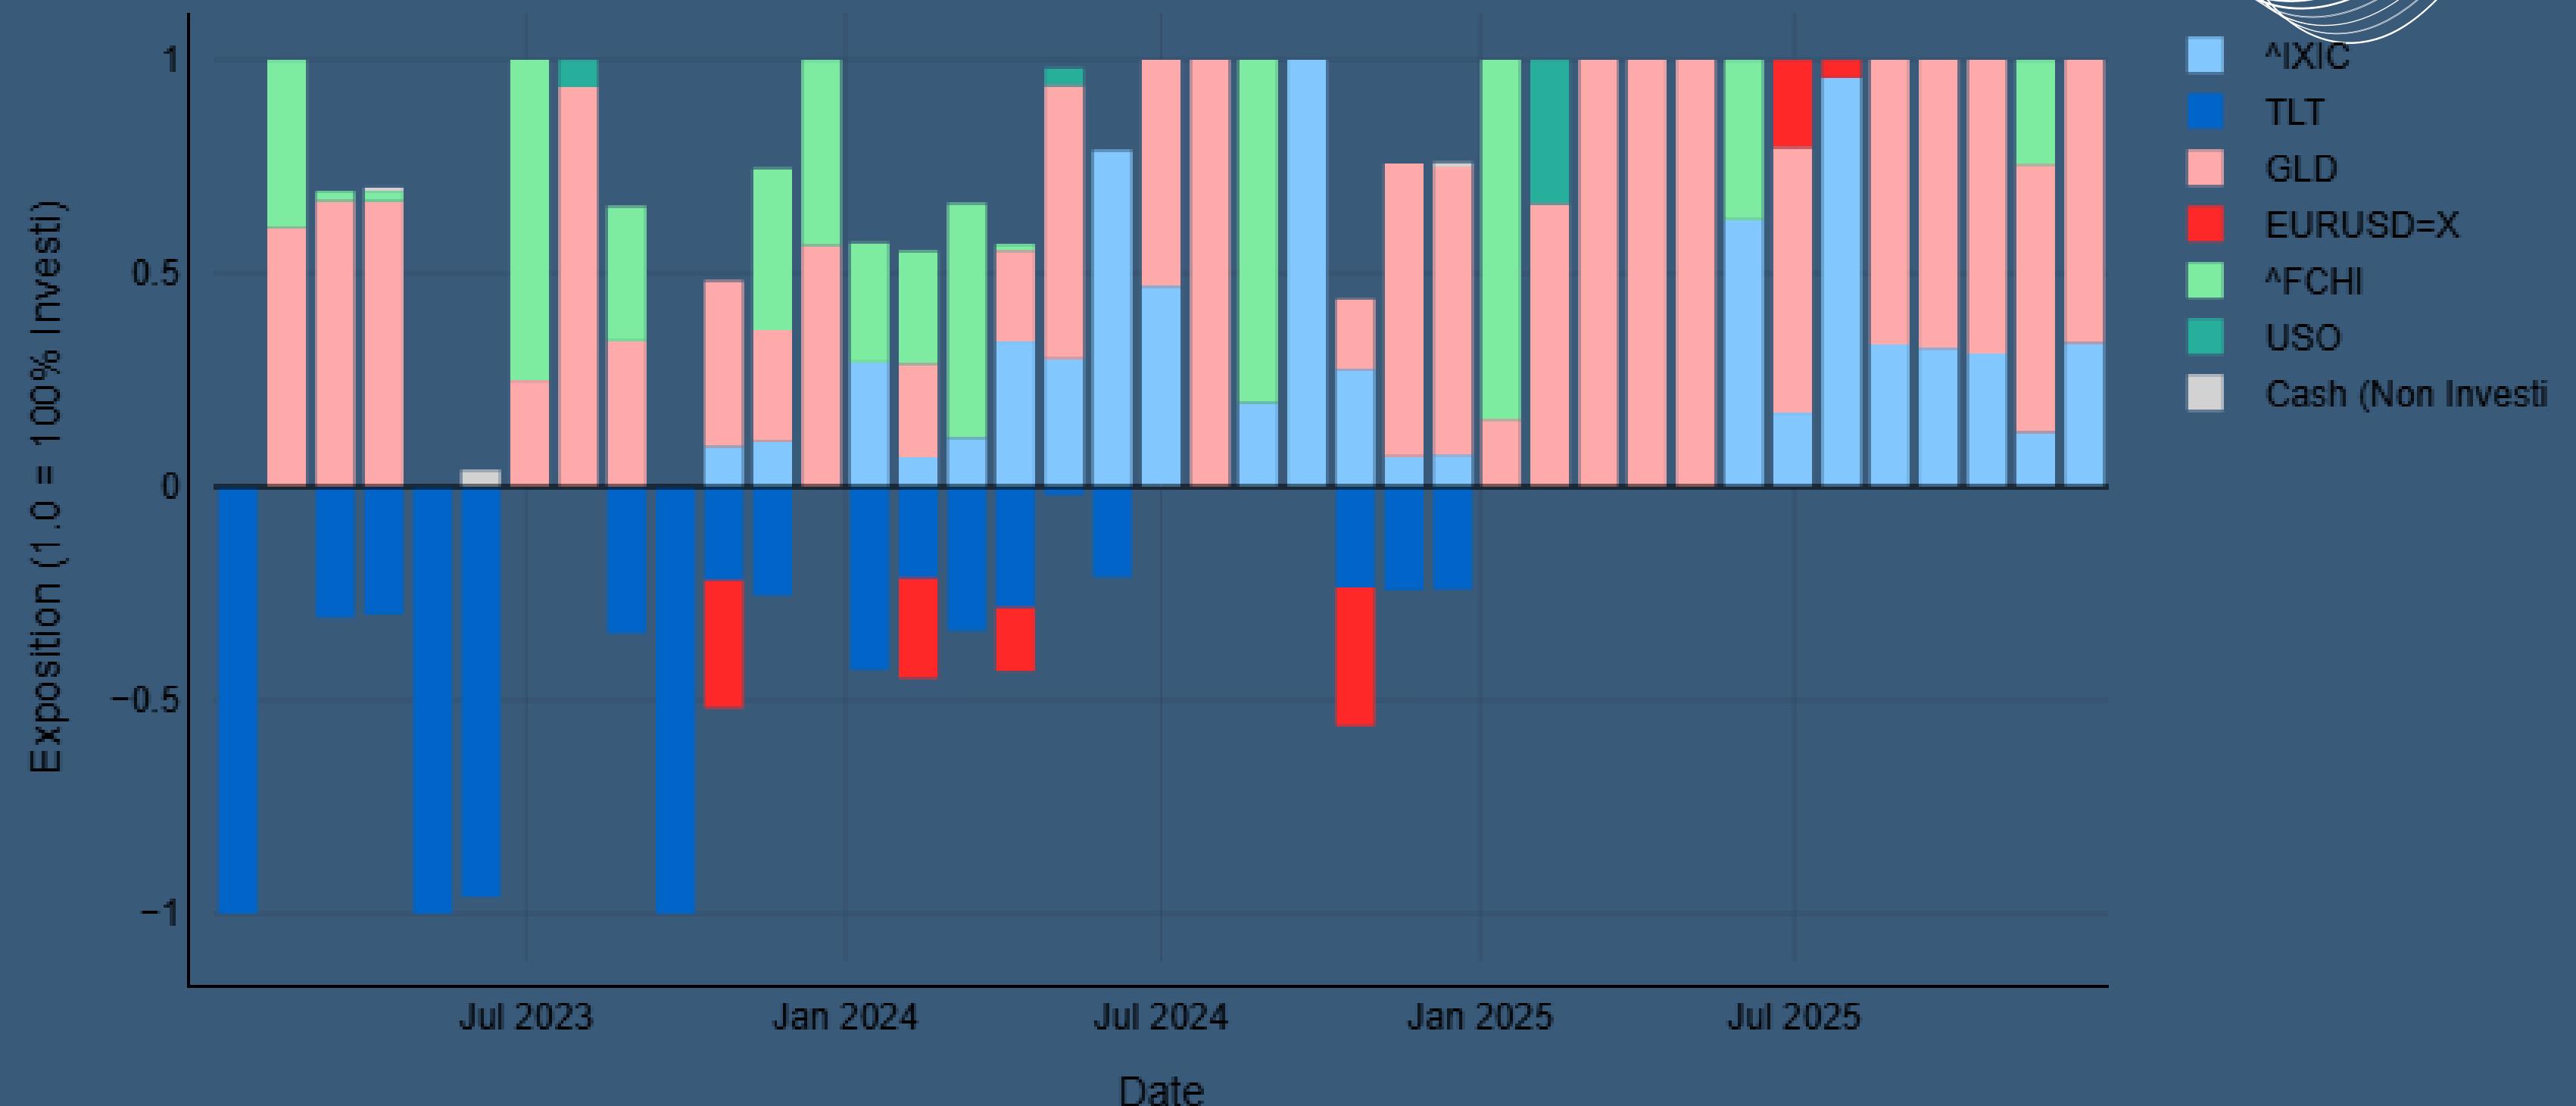


# Gestion de Portefeuille

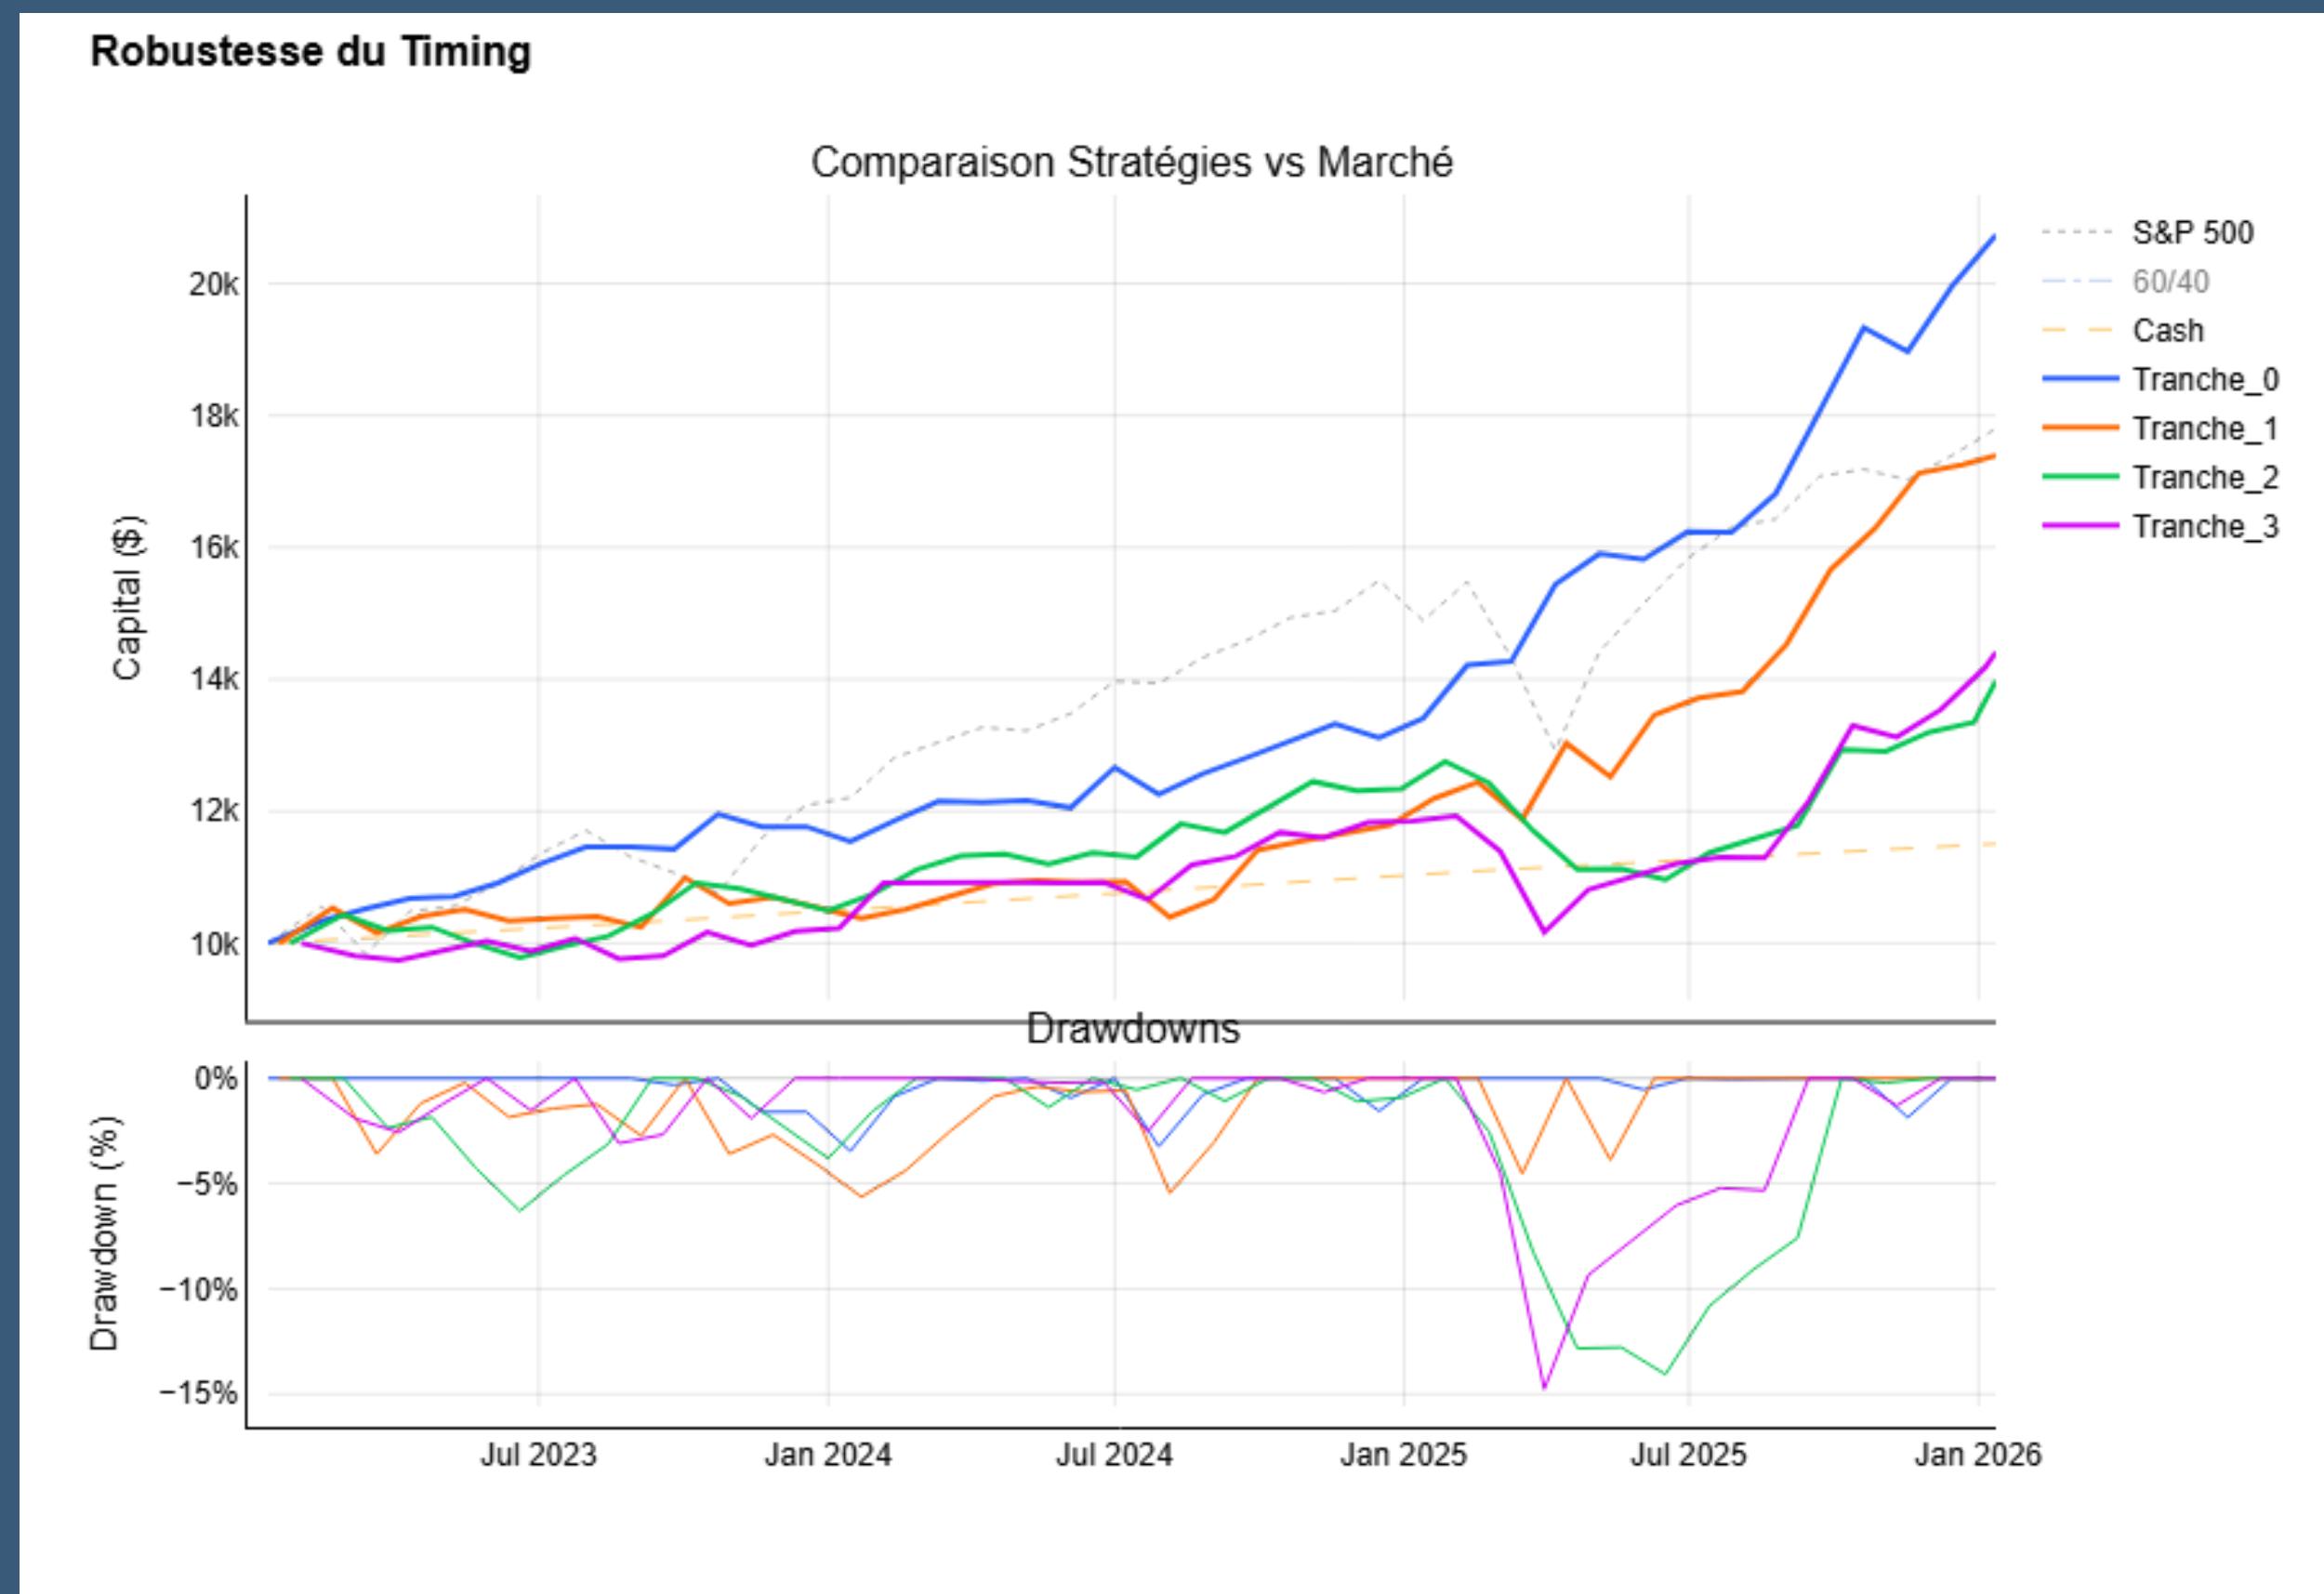


# Gestion de Portefeuille

## Allocation Dynamique (Exposition Nette)



# Gestion du Timing



# Conclusion

## Bilan méthodologique :

- GARCH : Indispensable pour modéliser la variance
- ML/DL : efficaces pour capter les non-linéarités, moins précis sur le niveau, mais pertinents pour la direction

## Implications :

- Un modèle n'a pas besoin d'être parfait point par point pour être rentable
- Stratégie hybride privilégie la protection du capital

## Limites :

- «Biais Conservateur» des modèles: sous-estime les mouvements extrêmes
- Perspective : Intégration du NLP pour capter la psychologie de marché

